

图像处理与机器视觉：课程全景笔记

复旦大学 - 智能科学与技术

2026 年春季学期

第一周：课程导论 (Introduction to Machine Vision)

机器视觉的研究范畴与目标

机器视觉的终极目标是赋予计算机（超越）人类水平的视觉感知能力，实现从 ** 像素级别 (Pixel to Pixel)** 到 ** 高级语义符号 (Pixel to Symbol)** 的理解。当前前沿研究范畴包括：

- **Deepfake 检测 (AIGC Detection)**: 识别合成视频与虚假视觉内容，作为数字真实性的关键防御手段。
- **具身智能 (Embodied AI)**: 结合视觉、语言与动作 (Vision-Language-Action Model)，涵盖具身交互与脑机接口。
- **多模态大模型安全 (Multimedia Model Security)**: 包含对抗攻击 (Adversarial Attack, 如原版视频可正确分类，加入弹幕扰动后模型失效) 与越狱攻击 (Jailbreak Attack)。

核心任务与面临的挑战 (Tasks & Challenges)

核心任务按颗粒度分为：** 图像分类 ** (识别类别)、** 物体检测 ** (识别类别 + Bounding Box 空间位置)、** 语义分割 ** (像素级识别同类对象) 和 ** 实例分割 ** (像素级区分同类中的不同个体)。

让计算机“看懂”世界的难点在于：

1. **数据多样性 (Data Variety)**: 包含视角变化、物体形变、光照条件差异、物体遮挡、背景杂乱以及类间差异小/类内差异大。
2. **数据与标签问题 (Quantity & Quality)**: 长尾效应（如正常驾驶数据极其丰富，但危险驾驶数据极少）及标签质量参差不齐。
3. **算力挑战 (Computing)**: 边缘计算 (Edge AI) 对低功耗、低延迟、轻量化模型的要求。
4. **算法脆弱性 (Vulnerability)**: 深度神经网络极易受对抗样本欺骗，对微小扰动表现出不稳定性。

发展史与课程考核 (History & Logistics)

- **历史演进**: 1960 年代 (Larry Roberts 开启 3D 多边形研究, MIT Summer Vision Project) → 1970-80 年代 (几何与数学模型) → 1990-00 年代 (人脸识别、统计分析) → 2010 年代至今深度学习时代。

- **现代模型演进**: 解析模型从 CNN (AlexNet/YOLO) → Transformer (ViT) → 状态空间模型 (Vision Mamba, 2024); 生成模型从 GAN → Diffusion (Sora) → LMM。
- **学术资源**: 顶级会议为 CVPR (在 Google Scholar 出版物排名中位列所有学科第 4)、ICCV、ECCV; 权威期刊为 TPAMI、TIP、IJCV。

第一周: 数字图像基础与空间域滤波 (Image Processing Basics)

数字图像的定义与形成

数字图像是客观场景的离散化近似表示。其物理形成过程由 ** 光源照射能量 ** 与 ** 物体表面反射率 ** 共同决定, 随后在成像系统中经过以下两个步骤完成数字化:

1. **采样 (Sampling)**: 空间坐标 (x, y) 的离散化, 决定图像分辨率。
2. **量化 (Quantization)**: 亮度/幅度值的离散化 (通常为 8-bit, 即 0-255)。

** 常见像素格式 ** 1 通道 (灰度/黑白)、3 通道 (RGB)、4 通道 (RGB + Alpha 不透明度通道)。

色彩空间 (Color Spaces)

- **RGB**: 基于红绿蓝三原色构建, 适合硬件显示, 但亮度与色度高度耦合。
- **HSV**: 包含色相 (Hue, 颜色种类, 用角度表示)、饱和度 (Saturation, 纯度) 和明度 (Value)。其解耦特性非常符合人类直觉。
- **L*a*b***: 感知均匀 (Perceptually uniform) 空间, L 表示亮度, a 和 b 为颜色对立维度, 能完美反映人眼对色差的感知。

空间域滤波基础 (Spatial Filtering)

滤波的本质是通过滑动窗口 (Kernel) 计算局部邻域像素的加权和。

- **均值滤波 (Box Filter)**: 简单的局部平均, 起平滑作用, 但会模糊边缘。
- **高斯滤波 (Gaussian Filter)**: 权重服从二维正态分布, 越靠近中心权重越大。

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (1)$$

** 核心优势 (可分离性 Separability) **: 二维高斯卷积可以拆分为两次一维卷积 (先按行后按列), 使得计算复杂度从 $\mathcal{O}(n^2m^2)$ 断崖式降至 $\mathcal{O}(n^2m)$ 。

三种常见噪声说明

- **椒盐噪声 (Salt-and-pepper noise)**: 随机出现的黑 (椒) 和白 (盐) 像素点, 常见于传感器故障或传输错误。
- **脉冲噪声 (Impulse noise)**: 随机出现的白像素点, 可视为椒盐噪声的单极版本。
- **高斯噪声 (Gaussian noise)**: 像素强度变化服从高斯分布 $\eta(x, y) \sim \mathcal{N}(\mu, \sigma)$, 常见于低光照或热噪声场景。

数学模型假设: 噪声是多个独立因素叠加的结果, 通常假设为独立、零均值。

非线性滤波与纹理表示

- **中值滤波 (Median Filter)**: 取邻域像素中位数, 能完美去除 ** 椒盐噪声 (Salt-and-pepper noise)** 且不模糊边缘。
- **双边滤波 (Bilateral Filter)**: 保边平滑滤波器。其权重同时考虑了 ** 空间距离 ** (越近权重越大) 和 ** 像素值差异 ** (亮度越接近权重越大), 从而在平滑噪声的同时锁定边缘。
- **纹理表示 (Texture Representation) 与滤波器组 (Filter Banks)**: 纹理描述了图像中像素强度的 ** 空间排列、重复模式与表面质感 ** (如粗糙度、平滑度、规律性、颗粒度)。通过应用不同方向 (Orientations) 和尺度 (Scales) 的滤波器组, 提取边缘 (Edges)、斑点 (Spots) 和条纹 (Bars)。提取后, 可通过计算绝对响应的统计量 (均值、标准差) 或对响应向量进行聚类 (生成直方图) 来表征纹理。

低通滤波与高通滤波

2.6.1 低通滤波 (Low-pass Filter)

低通滤波保留图像中的低频分量, 抑制高频分量。

- **低频分量**: 图像中变化缓慢的部分, 如平坦区域、背景。
- **高频分量**: 图像中变化剧烈的部分, 如边缘、噪声。
- **效果**: 平滑图像、去除噪声、模糊细节。
- **典型滤波器**: 均值滤波 (Box Filter)、高斯滤波 (Gaussian Filter)。

滤波和权重为 1

$$\sum h(i, j) = 1$$

2.6.2 高通滤波 (High-pass Filter)

高通滤波保留图像中的高频分量, 抑制低频分量。

- **效果**: 突出边缘和细节, 去除平滑背景信息。
- **典型应用**: 边缘检测、图像锐化。
- **典型滤波器**: Sobel 算子、Laplacian 算子、自定义锐化核。

$$\sum h(i, j) = 0$$

2.6.3 对比总结

	低通滤波	高通滤波
保留分量	低频（缓慢变化）	高频（剧烈变化）
抑制分量	高频（边缘、噪声）	低频（平滑背景）
视觉效果	模糊、平滑	锐化、边缘突出
核权重和	$\sum h = 1$	$\sum h = 0$
典型应用	去噪、图像平滑	边缘检测、图像锐化

第二周：图像增强与质量评估 (Image Enhancement & IQA)

图像增强的目的是为了让图像对于特定任务更“有用”（如突出细节、去噪），** 它不增加新信息，而是强调现有信息 **。

空间域对比度调整 (Contrast Adjustment)

当图像偏暗或偏亮时，可通过灰度变换拉伸像素动态范围。

$$f_{ac}(a) = a_{min} + (a - a_{low}) \frac{a_{max} - a_{min}}{a_{high} - a_{low}} \quad (2)$$

为了避免极端噪声点影响拉伸效果，通常基于直方图百分位数（如丢弃前 1% 和后 1% 的像素）来设定 a_{low} 和 a_{high} 。

修正对比度拉伸 (Modified Contrast Adjustment)

当图像中存在极亮或极暗的噪声点时，直接使用全局最小/最大值进行线性拉伸会导致大部分像素仍集中在较窄的范围内，效果不佳。修正方法通过丢弃直方图两端的尾部噪声（例如前 1% 和后 1% 的像素），仅使用剩余像素的有效范围进行拉伸，从而获得更鲁棒的对比度增强。

设：

- a_{low} 为累积直方图达到预设低百分位数（如 $S_{low} = 1\%$ ）时的灰度值
- a_{high} 为累积直方图达到预设高百分位数（如 $S_{high} = 99\%$ ）时的灰度值
- a_{min} 为目标输出最小灰度值（通常为 0）
- a_{max} 为目标输出最大灰度值（通常为 255）

则修正后的对比度拉伸变换为：

$$f_{ac}(a) = \begin{cases} a_{min}, & a \leq a_{low} \\ a_{min} + (a - a_{low}) \cdot \frac{a_{max} - a_{min}}{a_{high} - a_{low}}, & a_{low} < a < a_{high} \\ a_{max}, & a \geq a_{high} \end{cases}$$

其中：

- a 为原始像素值

- $f_{ac}(a)$ 为增强后的像素值
- 对于灰度范围 $[0, 255]$ ，通常取 $a_{\min} = 0$, $a_{\max} = 255$

该方法可有效抑制噪声对对比度拉伸的干扰，使增强结果更符合人眼视觉感知。

直方图处理 (Histogram Processing)

直方图均衡化 (Histogram Equalization, HE): 旨在寻找一个映射函数 $T(r)$ ，使得输出图像的灰度直方图服从均匀分布，从而自动实现对比度最大化。核心利用累积分布函数 (CDF):

$$s_k = T(r_k) = \lfloor (K-1) \sum_{j=0}^k p_r(r_j) \rfloor \quad (3)$$

其中 K 为灰度级数 (如 256)， $p_r(r_j)$ 为像素出现的概率。H(a)/MN, MN 为图像尺寸，H(a) 为灰度级 a 的像素个数

图像质量评估 (Image Quality Assessment, IQA)

- **全参考指标 (FR-IQA)**: 需要完美的参考图。
 - 均方误差 (MSE): $MSE = \frac{1}{MN} \sum_i \sum_j [I(i, j) - K(i, j)]^2$
 - 峰值信噪比 (PSNR): $PSNR = 10 \log_{10} \left(\frac{MAX^2}{MSE} \right)$
 - 结构相似性 (SSIM): 综合亮度、对比度和结构。
- **无参考前沿方案 (NR-IQA & LMMs)**: 如课程中介绍的 **Q-SIT** 模型，它不仅输出量化的质量得分 (Scoring)，还能用自然语言解释 (Interpreting) 图像缺陷 (如“山脉的模糊程度为 A 级”)。其轻量化版本 **Q-SIT-MINI** (0.5B 参数) 将 FLOPs 降低 92%，延迟减少 51%，仅需 5.2GB 显存，专为边缘设备部署设计。

第二周: 频率域图像增强 (Frequency Domain Enhancement)

傅里叶变换与卷积定理

任何图像都可以分解为具有不同频率、幅度和相位的正弦/余弦波之和。一维连续傅里叶变换定义为 $F(u) = \int f(x) e^{-j2\pi ux} dx$ 。对于大小为 $M \times N$ 的图像，其二维离散傅里叶变换 (2D DFT) 为:

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi \left(\frac{ux}{M} + \frac{vy}{N} \right)} \quad (4)$$

卷积定理 (Convolution Theorem): 空间域的卷积操作等价于频率域的点乘操作:

$$f(x, y) * h(x, y) \iff F(u, v) \cdot H(u, v) \quad (5)$$

* 意义: 将图像和核转换到频率域后，直接相乘再做逆变换，计算大尺寸滤波器时极为高效。
*

频率域滤波特性与常见滤波器

使用 `fftshift` 后，低频（平滑背景、缓慢变化）位于频谱中心，高频（边缘、细节、噪声）位于四周。令 $D(u, v)$ 为频域点到中心的距离， D_0 为截止频率：

1. 理想低通滤波器 (Ideal LPF):

$$H(u, v) = \begin{cases} 1 & \text{if } D(u, v) \leq D_0 \\ 0 & \text{if } D(u, v) > D_0 \end{cases} \quad (6)$$

拥有绝对的截止边界。由于其在频率域是阶跃函数（矩形框），经过逆变换到空间域会变成 sinc 函数，从而产生严重的 ** 振铃效应 (Ringing Artifacts) **，导致图像边缘出现水波纹。

2. 巴特沃斯低通滤波器 (Butterworth LPF):

$$H(u, v) = \frac{1}{1 + [D(u, v)/D_0]^{2n}} \quad (7)$$

具有平滑的过渡带。阶数 n 越大，越接近理想滤波器，振铃效应越明显； n 较小时无明显振铃效应。

3. 高斯低通滤波器 (Gaussian LPF):

$$H(u, v) = e^{-D^2(u, v)/2D_0^2} \quad (8)$$

因为高斯函数的傅里叶逆变换仍然是高斯函数，因此 ** 完全不会产生任何振铃效应 **，过滤效果最平滑。相应的 ** 高斯高通滤波器 (GHPF) ** 为 $1 - H(u, v)$ 。

空间域与频率域综合对比总结

- **空间域 (Spatial Domain):** 直接操作像素 $g(x, y) = f(x, y) * h(x, y)$ 。计算简单直观，非常适合局部操作（如 3×3 窗口）。
- **频率域 (Frequency Domain):** $G(u, v) = F(u, v)H(u, v)$ 。具备强大的全局频率分析能力，极其适合处理周期性噪声（如陷波滤波）、全图特征操作，以及利用 FFT 加速大尺寸核滤波。

第三周：边缘与角点检测 (Edge & Corner Detection)

边缘和角点是图像中最重要的局部特征，承载了大量的结构与形状信息。边缘对应于强度发生突变的连续位置，而角点是轮廓的交汇点，具有更强的独特性和匹配鲁棒性。

基于梯度的边缘检测 (Gradient-Based Edge Detection)

图像梯度描述了强度在不同方向上的变化速率，是边缘检测的基础工具。定义梯度向量：

$$\nabla I = (I_x, I_y) \quad (9)$$

其中 I_x 为水平方向强度变化, I_y 为垂直方向强度变化。边缘的强弱由梯度幅值 (Magnitude) 衡量:

$$|\nabla I| = \sqrt{I_x^2 + I_y^2} \quad (10)$$

实际应用中常采用近似形式: $|\nabla I| \approx |I_x| + |I_y|$, 以减少计算量。梯度的方向指示强度上升最快的方位, 计算公式为:

$$\theta = \tan^{-1} \left(\frac{I_y}{I_x} \right) \quad (11)$$

需要特别注意的是, ** 边缘的方向垂直于梯度方向 **。

在数字图像中, 导数需用离散差分近似。常见的一阶梯度算子包括 Roberts、Prewitt 和 Sobel 算子, 通过卷积核估计 I_x 和 I_y 。简单的梯度边缘检测流程为: 平滑去噪 $\rightarrow$ 梯度计算 $\rightarrow$ 阈值筛选。但其结果往往存在边缘过宽、断裂或对噪声敏感等问题, 这推动了更先进的 Canny 检测器的发展。

三种经典梯度算子的比较

Roberts 算子使用 2×2 对角线差分核, 仅检测对角线方向的梯度:

$$G_x = \begin{bmatrix} +1 & 0 \\ 0 & -1 \end{bmatrix}, \quad G_y = \begin{bmatrix} 0 & +1 \\ -1 & 0 \end{bmatrix} \quad (12)$$

梯度幅值常近似为 $|\nabla I| \approx |G_x| + |G_y|$ 。由于核尺寸极小且无平滑, 对噪声最为敏感, 但定位精度较高。

Prewitt 算子在 3×3 邻域内进行等权重平均差分, 具备一定的噪声抑制能力:

$$P_x = \begin{bmatrix} -1 & 0 & +1 \\ -1 & 0 & +1 \\ -1 & 0 & +1 \end{bmatrix}, \quad P_y = \begin{bmatrix} -1 & -1 & -1 \\ 0 & 0 & 0 \\ +1 & +1 & +1 \end{bmatrix} \quad (13)$$

通过对邻域取平均, 其输出边缘较 Roberts 平滑, 但定位精度略有下降。

Sobel 算子在 Prewitt 的基础上为中心像素赋予更高权重 (系数 2), 更符合自然图像的梯度分布:

$$S_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}, \quad S_y = \begin{bmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ +1 & +2 & +1 \end{bmatrix} \quad (14)$$

梯度幅值通常计算为 $G = \sqrt{(S_x * I)^2 + (S_y * I)^2}$ 或近似为 $G \approx |S_x * I| + |S_y * I|$ 。Sobel 算子能在噪声抑制和边缘保留之间取得最佳平衡, 因此在实际工程中应用最广泛。

表 1 从核尺寸、设计思想、抗噪能力、定位精度和适用场景等方面对三者进行了总结。

Table 1: 三种经典梯度算子的对比

算子	核尺寸	设计思想	抗噪能力	定位精度	适用场景
Roberts	2×2	对角线局部差分, 无平滑	最差	较高	低噪声、锐利边缘图像
Prewitt	3×3	邻域平均差分, 等权重	中等	一般	噪声较多、边缘模糊的图像
Sobel	3×3	加权差分, 中心权重为 2	较好	较高	通用场景, 工程中应用最广

Canny 边缘检测器 (Canny Edge Detector)

Canny 边缘检测器旨在同时优化信噪比、定位精度和单一边缘响应，其完整的五步流程如下：

1. **高斯平滑 (Gaussian Smoothing)**: 使用高斯核 $G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}}$ 对图像滤波，抑制噪声。参数 σ 控制平滑程度：较大的 σ 检测大尺度边缘，较小的 σ 保留精细细节。
2. **梯度计算 (Gradient Computation)**: 对平滑后的图像，利用 Sobel 算子计算梯度分量 I_x, I_y ，进而得到幅值 $M(x, y) = \sqrt{I_x^2 + I_y^2}$ 和方向 $\theta(x, y) = \arctan(I_y/I_x)$ 。
3. **非极大值抑制 (Non-Maximum Suppression, NMS)**: 沿每个像素的梯度方向比较其梯度幅值与相邻像素。仅当该像素为局部最大值时才保留为候选边缘点，否则抑制，从而将边缘细化至单像素宽度。
4. **双阈值处理 (Double Thresholding)**: 设定高阈值 T_{high} 和低阈值 T_{low} 。幅值高于 T_{high} 的像素标记为强边缘 (Strong edge)；介于两阈值之间的标记为弱边缘 (Weak edge)；低于 T_{low} 的直接抑制。通常 T_{high} 取最大梯度幅值的某一高位百分比， T_{low} 为 T_{high} 的一定比例。
强边缘：梯度幅值大于高阈值的像素，确定为真边缘。
弱边缘：梯度幅值介于高低阈值之间的像素。
非边缘：梯度幅值低于低阈值的像素，被丢弃。
5. **边缘跟踪 by 滞后 (Edge Tracking by Hysteresis)**: 将所有强边缘作为可靠起点，递归搜索其邻域内的弱边缘并将其纳入最终边缘图。只有与强边缘相连的弱边缘得以保留，孤立的弱边缘被舍弃，有效降低噪声引起的虚假边缘。

频率域视角：Q: 能否在频域进行边缘检测？YES

边缘对应图像中的高频分量，因此理论上可通过频域**高通滤波**实现边缘检测：先对图像进行 FFT，乘以高通滤波器，再反变换。然而，频域方法在局部定位上不够精确，并可能引入振铃效应，实践中仍以空域 Canny 等检测器为主流。

Harris 角点检测器 (Harris Corner Detector)

角点是图像中二维亮度变化都极为剧烈的点，具有旋转不变性和较强的光照鲁棒性，非常适合于图像匹配和运动追踪。Harris 检测器通过分析局部窗口平移时的亮度变化来区分平坦区域、边缘和角点。

对一个固定窗口施加微小位移 $[u, v]$ ，窗口内强度变化的加权和可近似为：

$$E(u, v) \approx [u, v] M \begin{bmatrix} u \\ v \end{bmatrix} \quad (15)$$

其中 M 为**结构张量** (Structure Tensor)，由图像梯度的二阶矩构成：

$$M = \sum_{x, y} w(x, y) \begin{bmatrix} I_x^2 & I_x I_y \\ I_x I_y & I_y^2 \end{bmatrix} \quad (16)$$

$w(x, y)$ 是窗口函数，通常选为高斯权重，以便中心像素有更大的影响力。

为判定像素点的属性，Harris 提出**角点响应函数** (Corner Response Function)：

$$R = \det(M) - k \cdot [\text{tr}(M)]^2 \quad (17)$$

若记矩阵 M 的两个特征值为 λ_1 和 λ_2 ，则有 $\det(M) = \lambda_1\lambda_2$ ， $\text{tr}(M) = \lambda_1 + \lambda_2$ ，可将公式改写为：

$$R = \lambda_1\lambda_2 - k(\lambda_1 + \lambda_2)^2 \quad (18)$$

其中 k 为经验常数，通常取 $0.04 \sim 0.06$ 。根据 R 的数值与符号可进行如下分类：

- 若 λ_1 、 λ_2 均很小， $|R|$ 极小：属于**平坦区域** (Flat)。
- 若一个特征值远大于另一个， $R < 0$ ：属于**边缘** (Edge)。
- 若 λ_1 、 λ_2 均较大且量级相当， R 为较大正值：属于**角点** (Corner)。

实现步骤概述：

1. 将图像转为灰度图，使用 Sobel 算子计算水平与垂直梯度 I_x 、 I_y 。
2. 计算逐像素的乘积 I_x^2 、 I_y^2 、 I_xI_y ，并用高斯窗口加权求和，构建每个像素的结构张量 M 。
3. 对每个像素计算角点响应 $R = \det(M) - k[\text{tr}(M)]^2$ 。
4. 选取合适的阈值 T ，保留 $R > T$ 的候选角点。
5. 对候选角点执行非极大值抑制，剔除局部邻域内的重复响应，得到最终稳定的角点位置。

通过调节 k 、窗口大小、高斯平滑尺度 σ 和阈值 T ，可以控制检测出的角点数量与质量。在 OpenCV 中可使用 `cv.cornerHarris()` 函数直接实现。

边缘检测 vs 角点检测

- **边缘检测**捕获一维强度断裂的连续性，输出边缘曲线。Canny 检测器通过多阶段优化实现了细、连续、抗噪的边缘提取。
- **角点检测**寻找二维变化均剧烈的“兴趣点”。Harris 检测器利用局部结构张量的特征值分析，能有效区分平坦区域、边缘和角点，具备旋转不变性及一定光照鲁棒性，是图像匹配中的关键特征点提取方法。

第三周：低级特征 (Low-Level Features)

上一周我们学习了如何检测边缘和角点，但如何用紧凑、不变的描述子来表达这些特征，以适应不同的成像条件？这就需要设计可靠的图像特征。

为何需要图像特征？

原始像素值对光照变化、尺度缩放、旋转和视角变化极其敏感，无法直接用于跨图像的稳定匹配。因此我们需要从图像中提取 **** 特征描述子 (Feature Descriptor)****，将关键视觉信息编码为一个紧凑的向量，使其在典型的光度变换和几何变形下保持**不变性**。

图像特征的定义与类型

一个图像特征应当是图像中可测量、独特的属性，能以紧凑的形式表达重量级的视觉信息。常见的特征类型包括：

- **边缘特征 (Edge Features)**：表示强度突变，如 Sobel、Prewitt、Canny 检测结果。
- **形状特征 (Shape Features)**：描述物体的几何结构，如边界描述子、形状矩、傅里叶描述子。
- **纹理特征 (Texture Features)**：刻画重复性模式和表面属性，如 LBP、GLCM。
- **全局特征 (Global Features)**：从整幅图像计算，概括整体视觉特性，简单高效，但对遮挡和背景变化敏感。例子：颜色直方图、GIST。
- **局部特征 (Local Features)**：在检测到的关键点周围区域提取，通常对尺度、旋转、光照不变，适合精确匹配与识别。例子：SIFT、SURF。

一般原则：当关注图像整体外观时使用**全局特征**（如场景分类）；当需要**精确匹配或目标识别**时采用**局部特征**（如 SIFT 关键点匹配）。

经典特征示例

6.3.1 颜色直方图 (Color Histogram)

统计每个颜色区间 (bin) 内的像素频数，形成一个全局描述向量。

$$h_i = \text{落入第 } i \text{ 个 bin 的像素数}$$

通常先将颜色聚类以减少 bin 数（如对 24-bit 彩色图像，若直接用 256^3 bins 将过于巨大）。该特征计算简单，常用于基于内容的图像检索 (CBIR)，但**完全没有空间信息**，对照明变化和遮挡敏感。改进方法：将图像**分块**，对每块提取颜色直方图后再串联，以获得一定的空间分布信息。

6.3.2 纹理特征与 Textons

利用多方向、多尺度的 **** 滤波器组 (Filter Banks)****（如各向同性 Gabor 滤波器、高斯导数滤波器）对图像进行卷积，将每个像素的响应向量聚类，每一类代表一种 **** 纹理基元 (Texton)****。最终用纹理基元的直方图来描述图像纹理。

6.3.3 GIST 描述子

GIST 是一种固定长度的**全局描述子**，旨在捕捉场景的整体空间布局和粗略结构 (the gist)。计算流程为：

1. 使用 N 个多方向多尺度的 Gabor 滤波器计算图像响应。
2. 将图像划分为 4×4 的网格。
3. 对每个格子内的滤波器响应求平均。
4. 将所有格子的均值串联，得到一个 $4 \times 4 \times N$ 维向量（如 $N = 20$ 时得到 320 维）。

GIST 编码的是梯度方向的粗略空间分布，适用于场景分类和简单检索，但对精细物体识别能力有限。目前在许多任务中已被深度卷积特征所取代。

6.3.4 HOG 描述子 (Histogram of Oriented Gradients)

尚未在本课详述，但它是经典的局部特征，通过统计局部区域的梯度方向直方图来捕捉形状和外观信息，广泛应用于行人检测。

6.3.5 SIFT：尺度不变特征变换 (Scale Invariant Feature Transform)

SIFT 是计算机视觉历史上最具影响力的局部特征之一，其对尺度、旋转、光照变化和小视角变化具有很好的不变性，被认为是最优秀的局部描述子之一。

SIFT 特征的计算分为四个主要阶段：

1. **尺度空间极值检测** 构建尺度空间 $L(x, y, \sigma) = G(x, y, \sigma) * I(x, y)$ ，其中高斯核为

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}.$$

计算高斯差分图像 (DoG):

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma).$$

DoG 是尺度归一化拉普拉斯算子 $\sigma^2 \nabla^2 G$ 的近似: $G(x, y, k\sigma) - G(x, y, \sigma) \approx (k - 1)\sigma^2 \nabla^2 G$ 。在 DoG 金字塔中搜索 $3 \times 3 \times 3$ 邻域的局部极值点作为候选关键点。

2. **关键点精确定位** 对候选点进行精化，剔除低对比度点和边缘响应过强的点。简单方法：保留梯度幅值 $M_{i,j} > 0.1 \times \max(M)$ 的点。更精细的方法：利用尺度空间函数的泰勒展开，设定阈值（如 0.03）滤除低对比度点；计算 Hessian 矩阵的特征值之比，剔除比值大于 10 的强边缘点。
3. **方向分配** 为每个关键点分配主方向以实现旋转不变性。在关键点周围区域内，计算每个采样点的梯度幅值和方向：

$$m = \sqrt{(L_{x+1,y} - L_{x-1,y})^2 + (L_{x,y+1} - L_{x,y-1})^2}$$

$$\theta = \tan^{-1} \left(\frac{L_{x,y+1} - L_{x,y-1}}{L_{x+1,y} - L_{x-1,y}} \right)$$

以梯度幅值为权重，使用高斯窗加权，构建方向直方图（36 bin），检测最高峰值作为主方向。

4. **局部描述子生成** 在关键点周围取 16×16 的区域，划分为 4×4 个子块。每块计算 8 个方向的梯度直方图（各像素的梯度幅值作为权重贡献给相应方向），最终将所有子块直方图串联，得到一个 $4 \times 4 \times 8 = 128$ 维的特征向量。

SIFT 描述子具有高度的区分性。在一幅 500×500 的图像中通常可以检测出约 2000 个关键点；即使将图像缩放到 60% 并旋转 30 度，仍能获得 214 个稳健的匹配对。然而，当对象外观发生剧烈变化时，匹配点数会大幅减少。此外，如何高效地匹配两组局部特征、如何处理目标外的误匹配，是后续需要解决的问题。

全局特征 vs 局部特征

- **全局特征 (Global Features)** 概括整幅图像的统计特性（颜色、空间频率），计算简单，但对照明、遮挡和背景变化敏感，缺乏空间细节。
- **局部特征 (Local Features)** 在检测到的关键点周边区域构建描述子，对尺度、旋转、光照具有不变性，非常适合图像匹配和物体识别，但计算量相对较大。
- 经典全局特征：颜色直方图、GIST；经典局部特征：SIFT、SURF、HOG。

第四周：传统图像分类框架 (Traditional Image Classification Framework)

传统图像分类流程 (Traditional Pipeline)

传统图像分类的终极目标是将图像映射到对应的语义标签。整个分类过程通常被设计为一个高度模块化的流程，每个步骤都被独立设计和优化。

- **整体流程:** 输入图像 (Input Images) → 特征提取 (Feature Extraction, 例如 SIFT/HoG/LBP) → 特征编码 (Feature Encoding, 例如 BoVW/直方图) → 分类器 (Classifier, 例如 SVM/KNN) → 最终预测结果。
- **训练与测试阶段:** 在训练阶段，通过提取图像特征并进行特征编码，以此来训练分类器。在测试阶段，对新图像提取特征并编码后，送入训练好的分类器输出预测类别。

特征编码 (Feature Encoding)

从图像中提取的局部特征（如 SIFT、HOG）往往数量不一且无序，无法直接进行比较，而标准分类器则需要固定长度的向量作为输入。特征编码的核心思想是将局部描述子转换为全局表示，从而跨越局部特征与分类器之间的鸿沟。

7.2.1 视觉词袋模型 (Bag of Visual Words, BoVW)

视觉词袋模型是一个经典的特征编码方法，其基本假设是：在进行物体识别（验证）时，可以忽略局部特征的空间分布信息。

1. **字典学习 (Dictionary Learning):** 从训练集图像中提取 SIFT 等局部特征，并利用 K-means 聚类算法学习生成“视觉词汇表” (Visual vocabulary/Codebook)。如果训练集具有足够的代表性，该词汇表就可以具备“通用性”。
2. **特征编码 (Encode):** 对于每张新图像，将提取到的特征进行量化 (Quantization)，即把每个特征关联到空间中最近的聚类中心（视觉词）。随后统计各个视觉词出现的次数，生成一个固定长度的直方图 (Histogram) 或词袋向量。

BoVW 模型的优缺点:

- **优点:** 输出的特征向量长度固定。在很大程度上不受图像中物体位置和方向变化的影响。在按对象内容进行图像分类的任务中取得了巨大的成功。
- **缺点:** 由于没有显式利用视觉词的空间位置配置，该方法在定位图像内的物体时表现不佳。

7.2.2 TF-IDF 权重调整

在向量空间模型中，单纯统计词频存在局限，因为并非所有视觉词都具有同等的区分度。词频-逆文档频率 (TF-IDF) 被用作一种启发式方法来为每个词分配权重。它能够有效降低常见特征词的权重，其权重公式为：

$$n(w_{i,d})\alpha_i = n(w_{i,d}) \log \left(\frac{D}{\sum_{d'} 1[w_i \in d']} \right) \quad (19)$$

其中， $n(w_{i,d})$ 表示词频，对数项表示逆文档频率。

分类方法 (Classification Methods)

- **K 近邻 (K-Nearest Neighbors, KNN)**: 核心思想是基于最近的邻居对样本进行分类，认为相似的样本极有可能共享相同的标签。其工作流程是计算样本间的距离，选取 K 个最近邻，并通过多数投票法分配标签。KNN 是一种非参数的懒惰学习方法，没有显式的训练阶段，实现简单直接。
- **支持向量机 (Support Vector Machine, SVM)**: 核心思想是学习出一个能够分离不同类别的决策边界，并尽可能最大化类别之间的裕度 (Margin)。最优分离超平面仅由一小部分被称为“支持向量”的样本决定，且可通过核技巧 (Kernel trick) 处理非线性分类问题。SVM 在高维特征空间中极为有效，抗过拟合能力强，非常适合搭配 BoVW 特征使用。

第四周: 传统图像分割框架 (Traditional Image Segmentation Framework)

图像分割基础 (Image Segmentation Basics)

图像分割旨在将图像划分为一系列的像素集合，以提取出有意义的区域（一致性物体）、线性结构或形状。早期的图像分割技术主要包括区域分裂与合并以及能量最小化，而近期的技术主要依赖深度学习、基础模型等。核心方法分类包括：基于阈值 (Thresholding)、基于区域 (Region based)、基于能量最小化 (Energy minimization)、基于形状 (Shape based)、基于图的方法 (Graph-based) 和基于聚类 (Clustering)。

基于阈值的分割 (Thresholding Based Segmentation)

8.2.1 全局二值化 (Image Binarization)

通常应用一个全局阈值 T 将标量图像映射为二值图像。映射规则为：

$$J(x, y) = \begin{cases} 0 & \text{if } I(x, y) < T \\ 1 & \text{otherwise} \end{cases} \quad (20)$$

。由于直方图的谷底可能过于宽广导致难以定位极小值、图像细节导致的局部多极小值、噪声干扰以及多峰分布等原因，寻找一个理想的全局阈值往往面临困难。

8.2.2 Otsu 阈值化算法

Otsu 算法通过分析图像的灰度值直方图，旨在自动提供一个最优的全局阈值。该算法的核心是寻找一个能够最大化类间方差 (between-class variance) σ_b^2 的阈值。对于两类分割任务，类间方差定义为：

$$\sigma_b^2 = P_1(\mu_1 - \mu)^2 + P_2(\mu_2 - \mu)^2 = P_1 P_2 (\mu_1 - \mu_2)^2 \quad (21)$$

其中 P_1 和 P_2 分别表示两类的像素概率， μ_1 和 μ_2 为两类的灰度均值。算法通过遍历所有可能的灰度级 $t \in [0, L - 1]$ ，依次计算划分出的两类概率与均值，最终选出使 σ_b^2 最大的最优阈值 t 。

基于区域的分割 (Region Based Segmentation)

区域是指具有相似属性的连通像素组。区域的计算既依赖于特征相似性，也必须结合空间邻近性。

- **区域生长 (Region Growing)**: 算法从给定的种子像素 (Seed points) 开始，考察其周围的相邻像素。如果相邻像素未被标记，且与当前区域的相似度小于给定的阈值 T ，则将其加入区域中。该过程不断递归执行，直至没有新像素满足条件。仅依赖相似性准则是无效的，必须考虑像素间的空间邻接关系。
- **区域分裂与合并 (Region Splitting and Merging)**:
 - **分裂 (Splitting)**: 与从种子开始生长的思路相反，分裂法以整幅图像作为一个初始大区域，只要其内部不满足同质性条件，就利用二叉树等方法将其递归地细分为子区域。
 - **合并 (Merging)**: 作为分裂的逆过程，合并用于避免过分割。它从非常小的区域开始寻找相邻区域，如果它们联合起来满足同质性谓词条件（如具有相似的灰度级、方差），则将它们合并。

基于聚类的分割 (Clustering Based Segmentation)

不同于在局部空间中生长区域，聚类分割法选择在全球范围内根据相似度对像素进行分组。该方法将每个像素视为一个数据点，使用像素的 RGB 颜色特征以及空间坐标 (x, y) 进行全局聚类。

8.4.1 K-Means 聚类分割

K-Means 通过最小化数据点与其所属聚类中心之间的距离之和进行分割。

- **优点**: 算法简单且运行速度快。
- **局限性**: 需要人工提前指定聚类数量 K ，且结果对初始聚类中心的选择十分敏感。

在特征中加入空间坐标属性，可以显著提升基于 K-Means 的分割质量。

8.4.2 均值漂移 (Mean Shift)

均值漂移是一种基于数据密度的聚类方法，其核心思想是让每一个数据点向高密度区域（即模式 Modes）移动。它通过计算局部邻域 $N(x)$ 内数据点的平均位置来更新偏移向量，公式为：

$$m(x) = \frac{\sum_{x_i \in N(x)} x_i}{|N(x)|} - x \quad (22)$$

并在迭代中通过 $x \leftarrow x + m(x)$ 不断更新点的位置，直到收敛。

Mean Shift 的优缺点总结

- **优点：**不需要假设簇服从球形分布。只需设置唯一一个参数（窗口大小）。能自动发现可变数量的模式。对异常值具有鲁棒性。
- **缺点：**分割结果高度依赖于设定的窗口大小。算法计算代价高昂。不适合扩展到高维特征空间中处理。

第五周：深度学习基础 (Deep Learning Basics)

深度学习彻底改变了计算机视觉的范式，从手工设计特征转向**端到端**的特征学习。本节将介绍深度学习的基本概念、多层感知机、反向传播算法以及优化器选择等核心内容。

深度学习的定义与范式转移

- **传统流程：**数据采集 → 手工特征设计（如 SIFT, HOG）→ 分类器训练 → 评估。特征工程与分类器学习分离，高度依赖领域知识。
- **深度学习流程：**数据采集 → 端到端学习（特征学习 + 分类器学习）→ 评估。手工特征设计被完全移除，模型从数据中自动学习层次化的特征表示。


深度学习 = 学习特征 (Feature Learning) + 学习分类器。其关键在于学习能够解耦数据中复杂变换的表示。现代预训练大模型（如 CLIP、视觉大语言模型）甚至可以在未见过特定任务训练数据的情况下完成泛化。

深度学习成功的关键因素

1. **大数据 (Data)：**ImageNet（100 万张标注图像，1000 类）的创建为卷积神经网络提供了充足训练样本，且学到的特征可迁移到其他任务。计算机视觉领域的 arxiv 论文数量年增长 20%-30%。
2. **算力 (Computing)：**GPU 拥有数千个并行计算核心，相比 CPU 的少量通用核心，能高效处理神经网络的大规模矩阵运算。AI 芯片的算力自 2010 年以来逐年倍增。
3. **特征学习 vs 特征工程：**深度学习联合优化特征变换与分类器，可学习海量参数，更好地利用大数据；而传统手工特征参数少（通常只有 2-3 个），调优困难，开发周期长。
4. **深度结构的优势：**虽然一个包含足够多神经元的单隐层网络就能逼近任意连续函数，但浅层网络可能需要指数级的神经元数量才能表示某些函数（如 d-bit 奇偶校验）。深层结构可以分层复用中间表示，用远更少的神经元完成同等复杂的映射，显著提升效率。

柏拉图表征假说 (Platonic Representation Hypothesis)

柏拉图表征假说 (Platonic Representation Hypothesis) 是一个理论概念：它认为在人工智能 (AI) 模型中，尤其是深度学习，随着模型规模的扩大和训练任务的多样化，**不同的模型在表示数据的方式上越来越趋于一致**。这种趋同指向一个共享的统计模型，这个模型能够捕捉到现实世界的基本结构，类似于古希腊哲学家柏拉图关于理想现实的概念。



世界 (Z) 可以用许多不同的方式来看待，如：图像 (X)，文本 (Y) 等。在每种模态上学习的表征将收敛到 Z 的类似表征。这一假说与柏拉图的洞穴寓言相联系，其中真实世界被视为理想的形式，而我们通过感官体验到的是这些理想形式的影子或映射。

All rights reserved by www.aias.top, mail: 179209347@qq.com

Figure 1: 柏拉图表征假说

特征工程 vs 特征学习

- **特征工程 (Feature Engineering):** 手工设计特征，参数少，依赖人类知识，与分类器分离开发，适应新应用慢。
- **特征学习 (Feature Learning):** 自动学习层次化表示，参数多，充分利用大数据，与分类器联合优化，快速适应新任务。深度网络表示甚至可能收敛到共享的“柏拉图表示”。

多层感知机与激活函数 (Multi-Layer Perceptrons & Activation Functions)

9.3.1 从线性到非线性

线性分类器 $f(\mathbf{x}) = \mathbf{W}\mathbf{x}$ 无法解决 XOR 等非线性可分问题。引入隐藏层和激活函数后，两层神经网络 $f(\mathbf{x}) = \mathbf{W}_2 \phi(\mathbf{W}_1 \mathbf{x})$ 就可以拟合任意复杂度的决策边界。其中 $\mathbf{x} \in \mathbb{R}^d$, $\mathbf{W}_1 \in \mathbb{R}^{h_1 \times d}$, $\mathbf{W}_2 \in \mathbb{R}^{c \times h_1}$, $\phi(\cdot)$ 为激活函数。

9.3.2 常用激活函数

- **Sigmoid:** $\sigma(z) = \frac{1}{1+e^{-z}}$ ，输出范围 (0,1)，曾广泛使用但易导致梯度消失。
- **Tanh (Hyperbolic Tangent):** $\tanh(z) = \frac{e^z - e^{-z}}{e^z + e^{-z}}$ ，输出范围 (-1,1)，零中心化，梯度比 Sigmoid 更强，但仍存在梯度消失问题。
- **ReLU (Rectified Linear Unit):** $f(s) = \max(0, s)$ ，分段线性，计算简单，缓解梯度消失，但负半轴硬饱和 (梯度为 0)。

- **LeakyReLU**: 在负半轴引入一个很小的斜率, 解决 ReLU 的硬饱和问题。
- **Softmax**: 仅用于输出层, 将任意实值向量转化为概率分布:

$$f(s_k) = \frac{e^{s_k}}{\sum_{k'=1}^C e^{s_{k'}}}$$

- **其他**: Hard tanh ($\max(-1, \min(1, x))$)、Softplus ($\log(1 + e^s)$) 等。

反向传播 (Backpropagation)

反向传播是多层神经网络最核心的监督训练算法, 通过计算损失函数对每个权重的梯度, 并利用梯度下降更新参数。

9.4.1 损失函数 (Loss Function)

- 均方误差 (MSE): $J(\mathbf{w}) = \frac{1}{2} \sum_{k=1}^c (t_k - z_k)^2 = \frac{1}{2} \|\mathbf{t} - \mathbf{z}\|^2$, 要求网络输出与目标值的欧氏距离。
- 交叉熵 (Cross-Entropy): $J(\mathbf{w}) = -\sum_{k=1}^c t_k \log(z_k)$, 其中 $\{z_k\}$ 和 $\{t_k\}$ 均为概率分布 (通常通过 softmax 获得), 适合分类任务。

9.4.2 梯度下降与权值更新

在网络中, 对于输出层第 k 个神经元与隐藏层第 j 个神经元之间的权重 w_{kj} , 更新规则为:

$$\Delta w_{kj} = -\eta \frac{\partial J}{\partial w_{kj}} = \eta \delta_k y_j,$$

其中 $\delta_k = (t_k - z_k) f'(net_k)$ 为输出单元的敏感度 (对交叉熵损失和 softmax 输出的组合, $\delta_k = z_k - t_k$ 形式更简洁), f' 为激活函数的导数, η 为学习率 (Learning Rate)。隐藏层权重的更新则通过链式法则将输出层的误差反向传播。

9.4.3 随机梯度下降与 Mini-batch

- **批量梯度下降 (Batch GD)**: 使用整个训练集计算梯度, 每次更新都很准确, 但计算开销大。
- **随机梯度下降 (SGD)**: 每次随机选一个样本更新, 速度快但梯度估计的方差大, 可能导致损失震荡。
- **Mini-batch SGD**: 将数据划分为小批量 (如 32、64), 每批计算一次梯度。它兼顾了效率和梯度估计的可靠性, 是实际训练中的标准方法。一个 epoch 指遍历完所有 mini-batch。

9.4.4 更高级的优化器

- **SGD with Momentum**: 在更新时加入动量项 $\mathbf{v} \leftarrow \alpha \mathbf{v} - \eta \mathbf{g}$, $\theta \leftarrow \theta + \mathbf{v}$ 。能加速在一致方向上的更新, 并抑制震荡。
- **Adam**: 结合动量和自适应学习率, 收敛快, 广泛使用。但可能占用内存较多, 泛化性能有时略逊于 SGD。

- **AdamW**: 将权重衰减 (Weight Decay) 与自适应梯度更新解耦，训练更稳定，是当今大模型的标准优化器。

Table 2: 常用优化器对比

优化器	特点	优点	缺点
SGD	仅用当前梯度	简单、易理解	收敛慢，震荡明显
SGD+Momentum	加入历史梯度动量	更快更稳定	仍需要手动调节学习率
Adam	自适应学习率 + 动量	收敛迅猛，普适性强	内存占用大，有时泛化不如 SGD
AdamW	解耦权重衰减	更稳定，常用大模型	内存占用大

训练流程与调试

9.5.1 深度学习三步法

1. **定义函数集**: 选择网络结构 (全连接、CNN、Transformer 等)。
2. **定义损失函数**: 衡量预测值与真实值的差异。
3. **优化**: 利用梯度下降等算法寻找最小化总损失的参数 θ^* 。

9.5.2 学习曲线分析

- **训练误差**通常随 epoch 增加而下降。如果最终误差仍然很高，可能是欠拟合 (网络容量不足、数据困难或陷入局部极小)。学习率过低收敛慢，过高则可能震荡。
- **验证/测试误差**一般高于训练误差。若验证误差在训练后期上升，则表明发生了过拟合。此时应在验证误差最小时提前停止训练 (Early Stopping)。

9.5.3 应对过拟合的策略

- 增加训练数据量。
- 使用正则化 (L1/L2)。
- 采用 Dropout 随机丢弃神经元。
- 降低模型复杂度 (减少层数或神经元数)。
- 值得注意的是，**深度双下降 (Deep Double Descent)** 现象表明，当模型规模持续增大时，性能可能先下降后再次上升，因此单纯减少参数并非总是最优策略。

9.5.4 正则化 (Regularization): L1 与 L2

正则化是通过在损失函数中添加惩罚项来限制模型复杂度、防止过拟合的技术。最常见的两种形式是 L1 正则化和 L2 正则化。

基本思想：在原始损失函数 $J(\mathbf{w})$ 的基础上，加入一个对权重大小的惩罚项，使得优化目标变为：

$$\tilde{J}(\mathbf{w}) = J(\mathbf{w}) + \lambda R(\mathbf{w})$$

其中 $R(\mathbf{w})$ 是正则化项， $\lambda > 0$ 是控制惩罚力度的超参数（正则化强度）。 λ 越大，对复杂模型的惩罚越重。

L1 正则化 (Lasso):

$$R(\mathbf{w}) = \|\mathbf{w}\|_1 = \sum_i |w_i|$$

- 对权重的绝对值求和作为惩罚项。
- **核心效果：**倾向于产生**稀疏解**——即许多权重被精确推到零。这天然实现了特征选择，模型只保留最重要的特征对应的权重。
- 梯度更新时，每个权重都会被一个常数项拉向零，小权重很容易完全归零。

L2 正则化 (Ridge / Weight Decay):

$$R(\mathbf{w}) = \|\mathbf{w}\|_2^2 = \sum_i w_i^2$$

- 对权重的平方和作为惩罚项。
- **核心效果：**倾向于产生**平滑解**——权重整体被压缩到较小的数值，但不会精确为零。所有特征都被保留，只是影响力被抑制。
- 梯度更新时，每个权重按比例衰减（等价于权重衰减），较大的权重衰减得更快。

两种正则化对比：

Table 3: L1 正则化 vs L2 正则化

特性	L1 (Lasso)	L2 (Ridge)	混合 (Elastic Net)
公式	$\sum w_i $	$\sum w_i^2$	$\alpha \sum w_i + (1 - \alpha) \sum w_i^2$
权重效果	产生稀疏解，部分权重归零	所有权重缩小但不为零	兼具稀疏与平滑特性
几何直观	菱形约束区域，解落在坐标轴上	圆形约束区域，解均匀分布在象限内	介于两者之间
适用场景	特征多但真正相关特征少	特征都有一定贡献，避免过拟合	需要同时特征选择和权重压缩

在深度学习中的表达形式：

假设原始损失为 J ，加上 L2 正则项（权重衰减）后，总损失及梯度变为：

$$\tilde{J} = J + \frac{\lambda}{2} \|\mathbf{w}\|^2, \quad \frac{\partial \tilde{J}}{\partial \mathbf{w}} = \frac{\partial J}{\partial \mathbf{w}} + \lambda \mathbf{w}$$

因此每一步 SGD 的权重更新变为：

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \frac{\partial J}{\partial \mathbf{w}} - \eta \lambda \mathbf{w}$$

可以看到，每次更新权重都会先乘以一个小于 1 的因子 $(1 - \eta\lambda)$ ，因此被称为权重衰减。正如正文中所介绍的，**AdamW 优化器**正是通过将权重衰减与自适应梯度更新解耦，使得 L2 正则化在大模型训练中更稳定且有效。

深度学习的应用与展望

深度学习已广泛渗透到图像识别、自动驾驶、图像编辑、大语言视觉模型（如 Sora、Veo3）等各个领域。未来网络结构的设计将更加自动化，而端到端学习范式也将继续推动通用人工智能的发展。

第六周：卷积神经网络 (Convolutional Neural Networks, CNN)

卷积神经网络利用图像的结构先验，通过局部连接和权重共享大幅减少参数量，是计算机视觉领域最重要的深度学习架构之一。

图像中的结构先验与卷积

图像中存在大量重复的局部模式（如边缘、纹理），因此一个滤波器应当在整个图像上**共享和复用 (Re-use and Share)**，以检测不同位置的相同模式。卷积神经网络正是基于这一思想，使用可滑动的卷积核替代全连接层。

10.1.1 卷积运算 (Convolution Operation)

一个 3×3 的卷积核在位置 (k, l) 上的响应为：

$$z(k, l) = \sum_{i,j=-1}^1 W(i, j) x(k + i, l + j) \quad (23)$$

输出特征图 (Feature Map) 的尺寸由**填充 (Padding)**、**步长 (Stride)** 和**卷积核尺寸 (Filter Size)** 共同决定，计算公式为：

$$\text{Output Size} = \frac{n + 2 \times \text{pad} - d}{\text{stride}} + 1 \quad (24)$$

其中 $n \times n$ 为输入特征图的空间尺寸， $d \times d$ 为卷积核大小。

- 无填充 (no padding)、步长 1：输出尺寸为 $n - d + 1$
- 有填充、步长 1：输出尺寸为 $n + 2 \times \text{pad} - d + 1$
- 有填充、步长 2：输出尺寸约为输入的一半

对于 RGB 三通道图像，每个卷积核也必须具有相同的通道数，对三个通道分别进行卷积再求和，输出单通道特征图。一个卷积层包含多个卷积核，每个核产生一个独立的输出通道。

池化层 (Pooling Layer)

池化通过下采样 (Subsampling) 缩小特征图空间尺寸，降低计算量并引入一定不变性。

- **最大池化 (Max Pooling)**: 在每个滑动窗口内取最大值。这是最常用的池化方式，没有可学习参数。
- 池化不改变通道数，只减小空间维度。

CNN 的参数压缩方式

相比于全连接网络，CNN 通过以下机制大幅减少参数：

1. **减少连接数**: 每个神经元只与局部感受野相连。
2. **权重共享**: 同一卷积核在整个图像上滑动时参数不变。
3. **池化层**: 进一步压缩特征图尺寸。

输入图像 → 卷积层 → 池化层 → 扁平化 → 全连接层 → 输出概率

卷积层的反向传播

卷积层的反向传播仍基于链式法则。由于前向传播中同一卷积核在不同位置共享权重，反向传播时需将各位置对该核权重的梯度累加，得到最终梯度。

经典 CNN 架构演进

10.5.1 LeNet-5 (LeCun et al., 1998)

最早的实用卷积神经网络之一，用于手写数字识别 (MNIST)。结构为：输入 32×32 → C1 (6 个 5×5 卷积) → S2 (池化) → C3 (16 个 5×5 卷积) → S4 (池化) → 全连接 → 输出 (10 类)。参数计算示例：C1 层的参数量为 $(5 \times 5 \times 1 + 1) \times 6 = 156$ 。(+1 为偏移量参数)

10.5.2 AlexNet (Krizhevsky et al., 2012)

2012 年 ImageNet 冠军，首次大规模使用 ReLU 激活函数。输入为 $227 \times 227 \times 3$ 图像，主要结构为：

- CONV1: 96 个 11×11 卷积核, stride=4, 输出 $55 \times 55 \times 96$, 参数 $(11 \times 11 \times 3) \times 96 \approx 35K$
- POOL1: 3×3 最大池化, stride=2, 输出 $27 \times 27 \times 96$, 参数为 0
- 后续包含四个卷积层、三个最大池化层和两个 4096 维的全连接层，最终 Softmax 输出 1000 类。

训练技术：ReLU、局部响应归一化、数据增强、Dropout 0.5、batch size 128、SGD Momentum 0.9、学习率 $1e-2$ 当验证误差平台时手动降低、L2 权重衰减 $5e-4$ 。

10.5.3 ZFNet (Zeiler & Fergus, 2013)

对 AlexNet 的微调：CONV1 改为 7×7 stride 2, CONV3-5 滤波器增多。ImageNet top-5 错误率从 15.4% 降至 14.8%。

10.5.4 VGGNet (Simonyan & Zisserman, 2014)

核心贡献：用多个堆叠的 3×3 卷积替代大卷积核。两层 3×3 卷积的感受野与一层 5×5 相同，但参数更少且非线性更强。

10.5.5 GoogLeNet / Inception (Szegedy et al., 2014)

提出 **Inception 模块**：在同一层并行使用 1×1 、 3×3 、 5×5 卷积和池化，将结果拼接，让网络自主选择最优多尺度特征。

10.5.6 ResNet (He et al., 2015)

ILSVRC 2015 所有赛道冠军。核心创新：**残差连接 (Residual Connection)** / **跳跃连接 (Skip Connection)**：

$$\text{Output} = \mathcal{F}(\mathbf{x}) + \mathbf{x} \quad (25)$$

通过恒等映射解决极深网络的退化问题，使 152 层 ResNet 的训练成为可能。

训练细节：每个卷积层后接批归一化 (Batch Normalization)，SGD + Momentum (0.9)，学习率 0.1，在平台后除以 10，Mini-batch 256，权重衰减 $1e-5$ ，无 Dropout。

10.5.7 DenseNet (Huang et al., 2016)

更激进的密集连接：**每层都接受前面所有层的输出作为额外输入**，在通道维度上拼接（而非 ResNet 的元素级相加）。损失函数曲面更加平滑，更易优化。

10.5.8 ResNeXt (Xie et al., 2017)

引入 **基数 (Cardinality)** 概念：将网络划分为多个相同拓扑的分支，对输入的不同分割并行处理。发现**增加基数比增加深度或宽度更有效**。

10.5.9 SENet (Hu et al., 2017)

最后一届 ImageNet 竞赛冠军。引入**通道注意力机制 (Channel Attention)**：

- **Squeeze**：全局平均池化将每个通道的空间信息压缩为一个标量
- **Excitation**：两个全连接层学习每个通道的重要性权重

将学习到的权重与原始特征图逐通道相乘，自动增强重要特征，抑制次要特征。

10.5.10 SKNet (Li et al., 2019)

引入**动态选择机制 (Dynamic Selection)**：

- **Split**：多路不同卷积核大小的分支
- **Fuse**：融合分支信息生成全局表示
- **Select**：根据特征预测注意力权重，动态聚合不同感受野的特征

10.5.11 ResNeSt (Zhang et al., 2020)

借鉴 ResNeXt 和 SKNet，设计 **Split-Attention 模块**：在多个相同拓扑的分支内，对每组特征分别进行全局平均池化和注意力权重计算，再重标定特征并融合。在分类、检测、分割上同时达到 SOTA。

10.5.12 HRNet (Sun et al., 2019)

核心创新：**始终保持高分辨率特征表示 (High-Resolution Representation)**。通过高、低分辨率子网络间反复交换信息 (Exchange Unit)，融合多尺度特征，使输出对位置敏感且语义丰富，适用于姿态估计、语义分割等精确定位任务。

10.5.13 EfficientNet (Tan & Le, 2019)

两个核心发现：

1. 扩大宽度、深度或分辨率都能提升准确率，但增益逐渐衰减
2. 平衡三者关系是提升效率与精度的关键

提出**复合缩放 (Compound Scaling)**：用统一系数同时缩放深度、宽度和分辨率。主要由 MBConv (反转残差块) 组成，并嵌入 SE-Block，在相同精度下大幅减少参数量和计算量。

10.5.14 RepVGG (Ding et al., 2021)

训练时多分支，推理时合并为单路：

- 训练阶段： 3×3 卷积 + 1×1 卷积 + Identity 分支，并配合批归一化
- 推理阶段：通过**结构重参数化 (Structural Re-parameterization)**，将 BN 合并到卷积权重中， 1×1 卷积和 Identity 分支均转换为等价的 3×3 卷积，最终合并为一个单一 3×3 卷积

兼具训练时的高精度和推理时的高速度，适合移动端部署。

CNN 在各类视觉任务中的应用

上述 CNN 架构作为通用骨干网络 (Backbone)，广泛支撑下游任务：

Table 4: CNN 在视觉任务中的典型应用

任务	典型模型	技术特点
目标检测 (Object Detection)	Faster R-CNN, Cascade R-CNN, SSD, YOLO	区域建议 + 分类回归
图像分割 (Semantic Segmentation)	FCN, DeepLab 系列, SegNet, U-Net, Mask R-CNN	全卷积 + 上采样/注意力
轻量级网络 (Lightweight Networks)	MobileNet 系列, ShuffleNet 系列, MixNet, Xception	紧凑设计，适合移动/嵌入端

轻量级网络常用技术包括：参数修剪与共享、低秩因子分解、紧凑卷积滤波器、知识蒸馏 (Knowledge Distillation) 和神经网络架构搜索 (NAS, Neural Architecture Search)。其目标是模型小、资源消耗低、计算速度快，易于部署在移动端和嵌入式设备上。

经典 CNN 架构演进总结

- **LeNet**: 奠定 CNN 基础
- **AlexNet / ZFNet / VGG**: 加深网络, 使用 ReLU、小卷积核堆叠
- **GoogLeNet**: 多尺度并行 Inception 模块
- **ResNet**: 残差连接, 突破深度限制 (152 层)
- **DenseNet / ResNeXt**: 密集连接与基数概念, 进一步优化特征复用
- **SENet / SKNet / ResNeSt**: 引入通道注意力与动态选择机制
- **HRNet**: 保持高分辨率表示, 适合位置敏感任务
- **EfficientNet**: 复合缩放, 平衡深度、宽度与分辨率
- **RepVGG**: 结构重参数化, 训练推理解耦, 适合实时部署

第七周: 视觉 Transformer (Vision Transformer, ViT)

Transformer 最初为自然语言处理中的序列到序列 (Seq2Seq) 任务而设计, 现已成功跨界到计算机视觉领域, 成为与 CNN 互补甚至更具优势的骨干架构。本周将首先介绍 Transformer 的核心组件, 然后讲解视觉 Transformer 的工作原理, 最后讨论 CNN 与 Transformer 的混合架构。

空间智能 (Spatial Intelligence)

多模态大语言模型 (MLLMs) 在处理多图像空间推理时仍会出现“空间坍塌”等幻觉, 说明空间智能是当前研究的前沿问题。本节从 Transformer 网络讲起, 为理解视觉模型的空间信息处理打下基础。

Transformer 网络基础 (Transformer Networks)

Transformer 是一种完全的注意力机制架构, 由编码器 (Encoder) 和解码器 (Decoder) 两部分堆叠而成, 完全摒弃了循环结构。在视觉任务中主要使用编码器部分 (如 ViT)。

11.2.1 自注意力 (Self-Attention)

自注意力的核心是让每个输入元素 (如单词或图像块) 在编码时都能参考序列中其他所有元素的信息。其计算涉及三个可学习的投影矩阵:

- **Q (Query)**: 查询向量, 代表“要查什么”
- **K (Key)**: 键向量, 代表“特征标签”
- **V (Value)**: 值向量, 代表“实际内容”

对于输入矩阵 $\mathbf{X}$, 注意力输出由以下步骤得到:

1. 计算分数 (Score): $\mathbf{S} = \mathbf{QK}^\top$, 衡量查询与键的匹配程度

2. 缩放与 Softmax: $\mathbf{A} = \text{Softmax}\left(\frac{\mathbf{s}}{\sqrt{d_k}}\right)$, d_k 是键向量的维度, 缩放防止梯度过大

3. 加权求和: 输出 $\mathbf{Z} = \mathbf{A}\mathbf{V}$

交叉注意力 (Cross-Attention) 则是将查询来自一个序列, 键和值来自另一个序列 (例如不同模态), 要求两个序列的维度相同。

11.2.2 多头注意力 (Multi-Head Attention)

将注意力机制复制多份 (头数 h), 每个头在不同线性子空间中关注不同位置和关系, 最后将各头的输出拼接并经过一个线性层, 得到最终的输出矩阵。公式为:

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O$$

其中 $\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V)$ 。多头注意力的好处是可并行捕捉多种不同的关系模式。

11.2.3 位置编码 (Positional Encoding)

由于自注意力本身不对输入顺序建模, 必须显式注入位置信息。

正弦-余弦位置编码: 为每个位置 k 生成一个 d 维向量, 第 $2i$ 和 $2i+1$ 维分别为:

$$PE(k, 2i) = \sin\left(\frac{k}{n^{2i/d}}\right), \quad PE(k, 2i+1) = \cos\left(\frac{k}{n^{2i/d}}\right) \quad (26)$$

其中 n 为用户设定的常数 (如 10,000)。这一编码天然能反映相对位置关系, 且可泛化到训练时未见过的序列长度。

旋转位置嵌入 (RoPE): 不同于将位置向量加到词嵌入上, RoPE 将位置信息通过旋转矩阵注入到查询和键向量中。对于位置 p 的每个维度对 $(2i, 2i+1)$, 变换为:

$$\begin{pmatrix} x'_{2i} \\ x'_{2i+1} \end{pmatrix} = \begin{pmatrix} \cos \theta_{p,i} & -\sin \theta_{p,i} \\ \sin \theta_{p,i} & \cos \theta_{p,i} \end{pmatrix} \begin{pmatrix} x_{2i} \\ x_{2i+1} \end{pmatrix}, \quad \theta_{p,i} = p/10000^{2i/d} \quad (27)$$

RoPE 天然建模相对距离, 无需额外可学习参数, 已广泛应用于 LLaMA 等大模型。

11.2.4 层归一化 (Layer Normalization, LN)

与批归一化 (BN) 不同, 层归一化对每个样本的特征维度做归一化, 不受 batch size 影响, 适合 Transformer 序列建模。公式为:

$$\mu_l = \frac{1}{d} \sum_{i=1}^d x_i, \quad \sigma_l^2 = \frac{1}{d} \sum_{i=1}^d (x_i - \mu_l)^2 \quad (28)$$

$$\hat{x}_i = \frac{x_i - \mu_l}{\sqrt{\sigma_l^2 + \epsilon}} \quad (29)$$

$$y_i = \gamma \hat{x}_i + \beta \quad (30)$$

其中 γ 和 β 为可学习的缩放和偏移参数。

为避免计算均值和方差的开销, 大语言模型中常采用更高效的 **RMSNorm**:

$$\text{RMSNorm}(\mathbf{x}) = \frac{\mathbf{x}}{\text{RMS}(\mathbf{x})} \odot \gamma, \quad \text{RMS}(\mathbf{x}) = \sqrt{\frac{1}{H} \sum_{i=1}^H x_i^2} \quad (31)$$

每个子层 (自注意力、前馈网络) 之后都使用残差连接和层归一化, 形成完整的 Transformer 编码器块。

视觉 Transformer (Vision Transformer, ViT)

ViT 将图像视为一系列“视觉单词”，直接应用标准的 Transformer 编码器进行图像分类。

11.3.1 ViT 工作流程

1. **图像分块 (Split Image into Patches)**: 将输入图像切割为固定大小 (如 16×16) 的非重叠块。对于 $224 \times 224 \times 3$ 的图像, 得到 $14 \times 14 = 196$ 个图像块。
2. **块嵌入 (Patch Embeddings)**: 将每个图像块展平成向量, 通过一个可训练的线性投影层映射到固定维度 (如 768)。这一步等价于使用卷积核大小和步长均为块大小的二维卷积。
3. **添加 [cls] 令牌与位置嵌入**: 在块嵌入序列前面添加一个可学习的 [cls] 令牌 (classification token), 该令牌在编码器输出端用于最终分类。同时加入可学习的或预定义的位置嵌入, 整个序列长度为 $196 + 1 = 197$, 维度为 768。
4. **Transformer 编码器**: 将带有位置信息的嵌入序列输入由多头自注意力和前馈网络堆叠而成的编码器, 得到每个令牌的输出表示。
5. **分类头 (MLP Head)**: 仅取输出序列中 [cls] 令牌对应的向量, 经过一个全连接层得到类别预测。

11.3.2 位置编码方式的对比

- **绝对位置编码 (Absolute Positional Encoding)**: 原始 ViT 使用可学习的 1D 位置嵌入, 每个位置对应一个向量。它关注绝对位置, 但在长序列泛化上较弱。
- **相对位置编码 (Relative Positional Encoding)**: 注意力分数取决于查询和键之间的相对距离, 而非绝对位置。它赋予模型平移等变性 (Translation Equivariance) 和平移不变形, 更符合视觉特性。

从理论上讲, 一个具有 N_h 个头、相对位置编码维度 $D_p \geq 3$ 的多头自注意力层, 可以表达任意一个核大小为 $\sqrt{N_h} \times \sqrt{N_h}$ 的卷积层。这意味着自注意力在表达力上是可以涵盖卷积的, 但需要足够的头数。

11.3.3 ViT 的性能与特点

- ViT 在小数据集 (如 ImageNet-1K, 130 万张图) 上容易过拟合, 性能不及 ResNet; 但在大数据集 (如 ImageNet-22K、JFT-300M) 预训练后超越 CNN。
- 数据增强 (如 DeiT 中采用的强增强和正则化) 可提升小数据上的 ViT 性能。
- ViT 从数据中学习到有意义的局部结构和位置嵌入: 相邻块的位置嵌入更相似。

CNN 与 Transformer 的混合架构

虽然 Transformer 擅长捕捉长距离依赖 (Long-range Dependence) 和自适应空间聚合, 但它在计算效率和对局部先验的利用上不如 CNN。因此, 有许多工作致力于结合两者优势。

Table 5: CNN 与 Transformer 特性对比

特性	CNN	Transformer
长距离依赖	较弱，需深层堆叠感受野才变大	天然全局建模，层内即可覆盖全图
空间聚合方式	固定的局部窗口，平移等变	自适应的全局聚合，但计算量大
计算效率	高效，参数共享，硬件优化成熟	注意力矩阵复杂度 $\mathcal{O}(N^2)$ ，对高分辨率图开销大
归纳偏置	强局部性、平移等变性	偏置弱，需大数据或增强策略

11.4.1 CNN vs Transformer

11.4.2 典型混合架构：CvT (Convolutional Vision Transformer)

CvT 在 Transformer 中引入卷积操作，将 CNN 的局部性和层次化结构与 Transformer 的长程表达能力融合：

- 每个阶段由 **卷积令牌嵌入 (Convolutional Token Embedding)** 代替 ViT 中的线性分块投影，使块嵌入过程本身包含局部空间先验。
- 在自注意力计算之前，用 **深度可分卷积投影 Q 和 K**，在保持全局感受野的同时增强局部建模，且不增加多少计算量。
- 整个网络呈现层次化结构：空间分辨率逐阶段降低，通道数逐阶段增加，与 CNN 的金字塔结构类似。

这种设计使模型在中小数据集上也表现得很好，无需超大规模预训练。

视觉任务中的应用与扩展

ViT 及其混合变体已普及到几乎所有视觉任务中，作为通用骨干网络 (Backbone) 支撑图像分类、目标检测、语义分割等。最新的多模态大模型（如视觉语言模型）中，ViT 常作为视觉编码器，与语言模型配合进行多模态理解与生成。

Transformer 关键组件速查

- **自注意力**: $\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V}$
- **多头注意力**: 多个注意力头并行，拼接后线性投影
- **位置编码**: 正弦-余弦绝对编码，或 RoPE 旋转位置嵌入
- **层归一化**: 对特征维归一化，RMSNorm 是大模型常用变体
- **ViT 流程**: 分块 $\rightarrow$ 线性嵌入 $\rightarrow$ 加 [cls] 和位置嵌入 $\rightarrow$ Transformer 编码器 $\rightarrow$ MLP 头
- **混合架构**: CvT 将卷积引入 Transformer，兼具局部先验与全局注意力

第八周：目标检测 (Object Detection)

目标检测是计算机视觉的核心任务之一，要求模型同时给出图像中所有预定义类别物体的空间位置（边界框，Bounding Box）和类别标签。相比于图像分类，目标检测需要同时回答“是什么”和“在哪里”，因此更具挑战性。

目标检测的基本思路与挑战

- **穷举搜索 (Exhaustive Search)**: 滑动窗口遍历所有可能位置和尺度，计算量极大，不现实。
- **区域提议 (Region Proposals)**: 先快速生成一组可能包含物体的候选区域，再对候选区域进行分类，大幅降低搜索成本。
- **尺度多样性**: 物体在图像中可能以任意尺度出现，需要捕获所有尺度。
- **多样化聚合理**: 没有单一最优的区域合并策略。
- **计算速度**: 候选区域生成本身也需要足够高效。

选择性搜索 (Selective Search)

一种经典的类别无关区域提议算法，基于层次化分组：首先对图像进行过分割得到超像素 (Superpixels)，然后利用贪心算法按相似度反复合并最相似的相邻区域，最后从不同层次收集所有的合并结果作为候选框。步骤顺序为：初始过分割 → 合并最相似区域 → 重复合并 → 收集多尺度提议。

两阶段目标检测框架 (Two-Stage Framework)

两阶段方法先生成类别无关的候选区域，再对每个区域进行分类和边界框精修。

12.3.1 R-CNN (Region-based CNN)

R-CNN 是两阶段方法的开山之作，流程为：

1. 使用**选择性搜索**从输入图像生成约 2000 个区域提议。
2. 每个区域提议被缩放到固定尺寸，送入 CNN 提取特征。
3. CNN 特征分别送入一个 SVM 分类器进行类别判定，和一组线性回归器对边界框坐标进行精化。

边界框回归 (Bounding Box Regression): 给定提议框 (P_x, P_y, P_w, P_h) ，回归器预测偏移量 (t_x, t_y, t_w, t_h) ，修正后的框为：

$$\hat{G}_x = P_x + P_w t_x, \quad \hat{G}_y = P_y + P_h t_y \quad (32)$$

$$\hat{G}_w = P_w e^{t_w}, \quad \hat{G}_h = P_h e^{t_h} \quad (33)$$

非极大值抑制 (Non-Maximum Suppression, NMS): 根据物体性分数 (Objectiveness Score) 和框间重叠度 (Intersection over Union, IoU)，保留局部得分最高的框，抑制高度重叠的低分框，去除重复检测。

R-CNN 的缺陷：训练慢（每张图需对 2000 个区域分别提取 CNN 特征）、推理慢（约 47 秒/张）、选择性搜索是固定算法无法学习。

12.3.2 Fast R-CNN

核心改进：将整张图像先通过 CNN 提取共享特征图，然后在特征图上对每个区域提议进行 **RoI Pooling** 得到固定尺寸的特征，再同时进行类别预测和边界框回归。这避免了重复卷积计算，大幅提升速度，但仍依赖外部的选择性搜索生成提议。

12.3.3 Faster R-CNN

提出**区域提议网络 (Region Proposal Network, RPN)**，直接在共享特征图上生成候选框，使整个系统成为端到端可训练的。RPN 使用锚框 (Anchor Boxes) 机制，以滑动窗口方式在特征图的每个位置预测多个候选框的物体性分数与回归偏移。整个网络联合训练四个损失：RPN 分类损失、RPN 回归损失、最终分类损失、最终回归损失。

一阶段目标检测框架 (One-Stage Framework)

一阶段方法跳过显式的区域提议过程，直接在密集采样的位置上同时预测类别和边界框，速度更快。

12.4.1 YOLO (You Only Look Once)

核心思想：将目标检测视为回归问题，单次前向传播即完成所有预测。

1. 将输入图像划分为 $S \times S$ 的网格（如 7×7 ）。
2. 每个网格单元预测 B 个边界框（每个框包含 $(x, y, w, h, \text{confidence})$ ）和 C 个类别概率。
3. 最终输出张量大小为 $S \times S \times (5B + C)$ 。
4. 推理时，将类别概率与置信度相乘得到每个框的最终分数，再经阈值过滤和 NMS 得到最终检测结果。

YOLO 极大提升了速度，但初始版本对小物体和密集型目标的检测精度不如两阶段方法。

基于 Transformer 的目标检测

目标检测同样受益于 Transformer 架构，涌现出端到端的检测新范式。

12.5.1 DETR (DEtection TRansformer)

将目标检测建模为集合预测问题：使用 CNN 骨干提取特征，经 Transformer 编码器-解码器直接输出固定数量的预测对象。每个预测由边界框坐标和类别标签组成。训练时通过匈牙利算法进行二分图匹配，在预测对象和真实标注之间建立一一对应。DETR 移除了锚框和 NMS 等手工组件，但存在收敛慢的问题（需约 300 个 epoch），其部分原因在于位置查询的表示不理想。

12.5.2 DAB-DETR 与 DINO

DAB-DETR 将解码器中的可学习查询替换为**动态锚框 (Dynamic Anchor Boxes)**，直接以框坐标作为查询并逐层迭代更新，引入显式的位置先验，加速收敛。

DINO (DETR with Improved DeNoising Anchor Boxes) 进一步引入对比去噪训练策略、混合查询选择等方法，显著提升了收敛速度和检测精度，成为该系列的代表性工作。

12.5.3 Relation-DETR (ECCV 2024)

从目标间位置关系的统计显著性出发，提出**宏观相关性度量 (Macroscopic Correlation, MC)**，基于皮尔逊相关系数衡量单张图中物体边界框之间的相关性：

$$MC = \frac{\sum_i \sum_{j:j \neq i} |\text{Pearson}(\mathbf{b}_i, \mathbf{b}_j)|}{N(N-1)} \quad (34)$$

其中 $\mathbf{b}_i = [x_i, y_i, w_i, h_i]$ ， N 为物体数量。当所有物体框完全线性相关时 $MC = 1$ ，无相关时 $MC = 0$ 。

Relation-DETR 引入**位置关系编码器 (Position Relation Encoder)**，对任意两个边界框之间的相对几何关系进行编码，确保平移和尺度不变性：

$$e(\mathbf{b}_i, \mathbf{b}_j) = \left[\log \left(\frac{|x_i - x_j|}{w_i} + 1 \right), \log \left(\frac{|y_i - y_j|}{h_i} + 1 \right), \log \left(\frac{w_i}{w_j} \right), \log \left(\frac{h_i}{h_j} \right) \right] \quad (35)$$

将关系矩阵经过正弦-余弦高维嵌入后，转换为多头注意力中的标量权重，并逐层进行**渐进注意力精化 (Progressive Attention Refinement)**：

$$\text{Attn}_{\text{self}}(\mathbf{Q}^l) = \text{Softmax} \left(\text{Rel}(\mathbf{b}^{l-1}, \mathbf{b}^l) + \frac{\text{Que}(\mathbf{Q}^l) \text{Key}(\mathbf{Q}^l)^\top}{\sqrt{d_{\text{model}}}} \right) \text{Val}(\mathbf{Q}^l) \quad (36)$$

该方法从位置关系这一新角度增强了 DETR 系列检测器。

性能评估 (Performance Evaluation)

12.6.1 交并比 (Intersection over Union, IoU)

$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}} \quad (37)$$

用于衡量预测框与真实框的重合度。通常设定一个阈值（如 0.5）， $\text{IoU} \geq \text{阈值}$ 则判定为正确检测。

12.6.2 精确率与召回率 (Precision & Recall)

- **真阳性 (True Positive, TP)**: $\text{IoU} \geq \text{阈值}$ 的检测
- **假阳性 (False Positive, FP)**: $\text{IoU} < \text{阈值}$ 或重复的错误检测
- **假阴性 (False Negative, FN)**: 未被检测到的真实物体

$$\text{Precision} = \frac{TP}{TP + FP} \quad (38)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (39)$$

12.6.3 平均精度 (Average Precision, AP) 与 mAP

以不同置信度阈值绘制**精确率-召回率曲线 (Precision-Recall Curve)**，曲线下的面积即为某一类别的 AP。对所有类别的 AP 取平均得到 **mAP (mean Average Precision)**，是目标检测最核心的评估指标。

COCO 数据集指标：COCO 是目标检测、分割和描述的大规模基准数据集（33 万张图片，150 万实例，80 类别）。其核心评价指标包括：

- **AP**：IoU 从 0.50 到 0.95 以 0.05 步长取平均的 mAP（主流指标）
- **AP₅₀**：IoU=0.50 时的 mAP（PASCAL VOC 指标）
- **AP₇₅**：IoU=0.75 时的 mAP（严格指标）
- **AP_{small} / AP_{medium} / AP_{large}**：按物体面积（ $< 32^2$, $32^2 \sim 96^2$, $> 96^2$ ）分别评价

目标检测框架演进总结

- **两阶段 (Two-Stage)**：R-CNN → Fast R-CNN → Faster R-CNN（引入 RPN，端到端），精度高但推理速度稍慢
- **一阶段 (One-Stage)**：YOLO 系列，单次前向传播直接回归，速度快
- **Transformer 检测器**：DETR → DAB-DETR → DINO → Relation-DETR，端到端无锚框，引入动态锚框和位置关系建模
- **评估**：IoU, Precision/Recall, AP/mAP, COCO 为标准基准

第九周：图像分割 (Image Segmentation with Deep Learning)

图像分割是计算机视觉中像素级的稠密预测任务，要求为图像中的每一个像素赋予类别标签。本周将重点讨论两种核心分割范式——**语义分割**和**实例分割**——以及代表性模型、上采样技术和评估指标。

语义分割与实例分割

- **语义分割 (Semantic Segmentation)**：为每个像素分配一个类别标签，但不区分同一类别的不同个体。
- **实例分割 (Instance Segmentation)**：为每个像素分配类别标签 + 实例 ID，区分同一类别中的不同实例。

语义分割经典模型

13.2.1 全卷积网络 (Fully Convolutional Networks, FCN)

FCN 是深度学习语义分割的先驱工作，核心创新在于将分类网络（如 AlexNet、VGG、GoogLeNet）改造为全卷积结构，使其能处理任意尺寸的输入并输出对应大小的分割图。

关键步骤：

1. **全连接层卷积化**：移除分类网络的全局平均池化和全连接层，替换为 1×1 卷积层，输出通道数为类别数（如 PASCAL 数据集的 21 类 = 20 类前景 + 背景）。
2. **上采样至原始分辨率**：通过转置卷积 (Transposed Convolution) 将粗略的特征图上采样回输入图像大小。
3. **跳跃连接 (Skip Connections)**：结合深层（语义强但分辨率低）和浅层（语义弱但细节丰富）特征，分别产生 FCN-32s、FCN-16s、FCN-8s 的预测。融合浅层特征后，分割边界更精细。
4. **逐像素 Softmax 交叉熵损失 + 反向传播**。

13.2.2 SegNet

采用**编码器-解码器 (Encoder-Decoder)** 架构：

- **编码器**：标准卷积 + 池化，逐步降低分辨率，提取高层语义。
- **解码器**：通过上采样恢复空间分辨率，再用可训练的卷积层对上采样结果进行精化。
- 最终 Softmax 层输出 K 通道的概率图， K 为类别数。

13.2.3 U-Net

在编码器和解码器对应层之间引入**跳跃连接**，将编码器的高分辨率特征直接拼接到解码器的对应层，极大保留了空间细节，特别适用于医学图像等需精确边界的场景。

上采样技术 (Upsampling Techniques)

将低分辨率特征图恢复到原始分辨率的常用方法：

1. **插值 (Interpolation)**：最近邻、双线性 (Bilinear)、双三次 (Bicubic) 等。无学习参数，双线性插值公式为：

$$P \approx \frac{y_2 - y}{y_2 - y_1} \left(\frac{x_2 - x}{x_2 - x_1} Q_{11} + \frac{x - x_1}{x_2 - x_1} Q_{21} \right) + \frac{y - y_1}{y_2 - y_1} \left(\frac{x_2 - x}{x_2 - x_1} Q_{12} + \frac{x - x_1}{x_2 - x_1} Q_{22} \right) \quad (40)$$

2. **固定反池化 (Fixed Unpooling)**：记住最大池化时最大值的位置，在上采样时将值放回原位置，其余置零。高效但较为粗糙。
3. **转置卷积 (Transposed Convolution)**：也称上卷积 (Up-convolution)，具有可学习的卷积核，是 FCN 和 SegNet 解码器的主力上采样方法。

实例分割：Mask R-CNN

Mask R-CNN 是实例分割的里程碑工作 (ICCV 2017 最佳论文奖)，在 Faster R-CNN 的基础上增加了一个分割掩码预测分支，三任务并行：**分类 + 边界框回归 + 分割掩码**。

RoIAlign vs RoIPool：Faster R-CNN 中的 RoIPool 在量化过程中进行最近邻取整，破坏了特征与像素之间的**平移等变性 (Translation Equivariance)**，影响分割精度。Mask R-CNN 提出 **RoIAlign**，使用**双线性插值 (Bilinear Interpolation)** 在非整数坐标处精确采样特征值，实现了像素到像素的对齐，显著提升分割质量。

Mask R-CNN 的总体流程：CNN 骨干提取特征 → RPN 生成区域提议 → RoIAlign 获得精确定义的固定尺寸特征 → 并行预测类别、边界框偏移和二值分割掩码（每个类别独立预测）。

评估指标 (Evaluation Metrics)

13.5.1 交并比与平均交并比 (IoU & mIoU)

对于语义分割，最基本指标为交并比 (Intersection over Union, IoU)。令 TP 、 FP 、 FN 分别为该类别的真正例、假正例、假负例（均以像素计）：

$$\text{IoU} = \frac{TP}{TP + FP + FN} \quad (41)$$

将所有类别的 IoU 取平均，得到**平均交并比 (mean IoU, mIoU)**，是语义分割最核心的评估指标。

13.5.2 平均精度 (mAP) 与实例分割评估

实例分割需同时评估检测框位置和掩码质量。常用指标为平均精度 (Mean Average Precision, mAP)，对每个实例同等重要：

$$mAP = \frac{1}{N} \sum_{t \in T} \frac{TP_t}{TP_t + FP_t + FN_t} \quad (42)$$

其中 T 为类别集合， N 为类别数。

主流基准数据集 (Benchmark Datasets)

Table 6: 常用图像分割数据集

数据集	特点	规模/应用场景
COCO	大规模检测、分割、关键点、描述数据集	33 万张图像，80 类，实例分割核心基准
Cityscapes	城市街景的语义、实例、稠密像素标注	30 类，3000+ 篇论文，自动驾驶核心数据集
KITTI	移动机器人与自动驾驶多传感器数据	2930+ 篇论文，含光流、测距、跟踪等任务
ADE20K	场景为中心的像素级物体与部件标注	2 万 + 张图像，150 个语义类别
DAVIS	高质量高分辨率稠密标注视频分割	480p/1080p，单目标/多目标视频分割
SYNTHIA	虚拟城市渲染的多视角照片级合成数据	9400 张，像素级语义标注，域自适应研究常用

此外，ShapeNet (3D CAD 模型)、ScanNet (室内 RGB-D 3D 标注)、S3DIS (室内 3D 点云语义分割)、GTA5 (合成数据域自适应) 等也是非常活跃的分割基准。

图像分割技术总结

- **语义分割**: FCN (全卷积 + 跳跃连接)、SegNet (编码器-解码器 + 转置卷积)、U-Net (对称跳跃连接)
- **上采样方式**: 插值、固定反池化、转置卷积 (可学习)
- **实例分割**: Mask R-CNN = Faster R-CNN + 掩码分支, 核心是 RoIAlign 替代 RoIPool
- **评估**: 语义分割用 mIoU; 实例分割用 mAP; COCO、Cityscapes 是最核心的基准

第九周：实际问题——数据不平衡与领域自适应 (Data Imbalance & Domain Adaptation)

前几周我们系统学习了 CNN、Transformer 以及目标检测等强大模型, 但在实际应用中, 模型的性能往往受制于两个核心问题: 训练数据的**长尾分布 (Long-tailed Distribution)** 导致的**数据不平衡 (Data Imbalance)**, 以及训练集与测试集分布不一致导致的**领域偏移 (Domain Shift)**。本周将深入讨论这两个问题的成因、影响及应对策略。

数据不平衡 (Data Imbalance)

14.1.1 理想 vs 现实的数据集

经典的学术数据集 (如 MNIST、CIFAR-10、ImageNet) 通常经过精心策划, 各类别样本数大致平衡。然而现实世界的数据集 (如 iNaturalist 物种分类, 包含超过 8000 个类别) 往往呈现出典型的**长尾分布**: 少数头部类别拥有海量样本, 而大量尾部类别只有极少量样本。

14.1.2 不平衡率 (Imbalance Ratio, IR)

衡量数据集不平衡程度的指标为:

$$IR = \frac{N_{\text{maj}}}{N_{\text{min}}} \quad (43)$$

其中 N_{maj} 为多数类的样本数, N_{min} 为少数类的样本数。当 $IR = 1$ 时数据集完全平衡; IR 越大, 不平衡程度越严重。例如, 一个医疗影像数据集若正常类有 5000 张, 罕见病类仅 50 张, 则 $IR = 100$, 属于严重不平衡。

14.1.3 数据不平衡对分类的影响

在极不平衡的数据上, 模型可能退化为只预测多数类, 虽然准确率 (Accuracy) 可达 98%, 但对少数类的召回率 (Recall) 为 0, 无法满足实际需求。因此, 评估不平衡分类问题时, 必须同时关注精确率 (Precision)、召回率 (Recall)、F1-score、平衡准确率 (Balanced Accuracy) 及 AUC 等指标。

14.1.4 应对数据不平衡的基本方法

重采样 (Resampling)

- **过采样 (Oversampling)**: 复制少数类样本, 增加其在训练中的出现频率。风险是容易过拟合尾部数据。
- **欠采样 (Undersampling)**: 丢弃部分多数类样本。风险是不可能丢失头部数据的重要分布信息。

阈值移动 / 类别平衡损失 (Thresholding / Class-Balanced Loss) 调整分类器的决策阈值, 或在损失函数中为不同类别赋予不同权重。

考虑到数据的有效样本数 E_n 是随 n 指数增长的:

$$E_n = \frac{1 - \beta^n}{1 - \beta}, \quad \beta = \frac{N - 1}{N} \quad (44)$$

基于此的**类别平衡损失 (Class-Balanced Loss, CB Loss)** 在标准损失前乘以权重因子:

$$\text{CB}(\mathbf{p}, y) = \frac{1}{E_{n_y}} \mathcal{L}(\mathbf{p}, y) = \frac{1 - \beta}{1 - \beta^{n_y}} \mathcal{L}(\mathbf{p}, y) \quad (45)$$

对于软最大交叉熵损失, 类别平衡版本为:

$$\text{CB}_{\text{softmax}}(\mathbf{z}, y) = -\frac{1 - \beta}{1 - \beta^{n_y}} \log \left(\frac{\exp(z_y)}{\sum_{j=1}^C \exp(z_j)} \right) \quad (46)$$

其中 n_y 为真实类别 y 的样本数, $\beta \in [0, 1)$ 为超参数。

14.1.1.5 重平衡技巧的潜在问题与最佳实践

- 重采样可能造成数据分布扭曲: 原始分布 99:1 的 100 张图像, 重采样至 50:50 后, 有效样本数从 100 降至仅约 51。
- 权重调整也可能直接改变或逆转原始分布。

两阶段实验的关键发现: 将分类模型拆分为**特征提取器 (Feature Extractor)** 和**分类器 (Classifier)** 两部分。

1. 阶段一: 用交叉熵损失 (或重平衡技巧) 共同训练特征提取器和分类器。
2. 阶段二: 冻结特征提取器参数, 仅用交叉熵损失 (或重平衡技巧) 从头重新训练分类器。

实验结果表明——**表示学习 (特征提取) 阶段应优先使用普通交叉熵损失以保留完整的分布信息, 分类器学习阶段才是应用重平衡策略的最佳时机。**这一发现具有重要的工程指导意义。

领域自适应 (Domain Adaptation)

14.2.1 数据集偏差与领域偏移 (Dataset Bias & Domain Shift)

当训练数据 (源域, Source Domain) 与测试数据 (目标域, Target Domain) 的分布不同时, 模型性能会急剧下降。典型的领域偏移场景包括:

- 从网络图片 → 机器人视角
- 从仿真环境 → 真实世界
- 从白天街景 → 夜间街景
- 从一个文化/人口群体 → 另一个群体

跨领域泛化的严重性: 即使在同一视觉概念 (如 “汽车”) 下, 不同数据集之间的性能降幅可达 28%–75%。因此, 解决数据偏差是模型实际部署的关键。

14.2.2 对抗性领域对齐 (Adversarial Domain Alignment)

通过对抗训练使得模型学习到**与领域无关的特征表示**，即无论输入来自源域还是目标域，特征分布都趋于一致。对齐可在两个层面进行：

- **特征空间对齐 (Feature-Space Alignment)**: 通过域判别器对中间特征进行对抗训练，使特征分布对齐。
- **像素空间对齐 (Pixel-Space Alignment)**: 直接改变图像的视觉风格以减少域差异（如 GTA 合成图像 $\rightarrow$ Cityscapes 真实街景的风格迁移）。

14.2.3 超越对抗对齐：类别偏移与特征解耦

类别偏移 (Category Shift) 与 **通用领域自适应 (Universal Domain Adaptation)** 传统无监督领域自适应假设源域和目标域的标签集相同（闭集）。但在实际中，源域类别 L_s 和目标域类别 L_t 的关系可能是：

- 闭集 (Closed-set): $L_s = L_t$
- 开集 (Open-set): $L_s \subset L_t$
- 部分集 (Partial): $L_t \subset L_s$
- 混合场景 (Open-Partial)

若使用闭集方法时目标域包含未知类别，模型会错误地将新类对齐到已知类，导致灾难性错位。通用领域自适应方法（如 **DANCE**）通过结合聚类损失 (Clustering Loss) 和熵分离损失 (Entropy Separation Loss) 来同时处理已知类别对齐和未知类别发现。

特征解耦 (Feature Disentanglement) 将特征分解为**领域无关成分 (Domain-Invariant Component)** 和**领域特有成分 (Domain-Specific Component)**。以年龄不变人脸识别为例：通过互信息最小化 (Mutual Information Minimization)，将人脸特征分解为**身份相关特征** 和**年龄相关特征**，仅使用身份特征进行识别，从而消除年龄变化对识别性能的影响。

14.2.4 开放长尾识别 (Open Long-tailed Recognition)

实际系统往往同时面临长尾分布和开放世界两个挑战——必须在判别多数类和少数类的同时，泛化到少量已知样本，并对从未见过的实例承认其未知性。这是领域自适应与数据不平衡研究的终极交汇点。

数据不平衡与领域自适应方法总结

- **数据不平衡:**
 - 衡量指标: 不平衡率 $IR = N_{maj}/N_{min}$
 - 应对方法: 重采样 (过/欠采样)、类别平衡损失 (CB Loss)
 - 最佳实践: 表示学习阶段用普通交叉熵, 分类器学习阶段用重平衡技巧
- **领域自适应:**
 - 对抗性对齐: 特征空间对齐 (域判别器) + 像素空间对齐 (风格迁移)
 - 通用领域自适应: 处理未知类别偏移, DANCE 等聚类 + 熵优化方法
 - 特征解耦: 分离领域不变与领域特有成分, 如年龄-身份解耦
- **交汇前沿:** 开放长尾识别——同时应对数据不平衡与类别未知性

第十周: 弱监督与半监督 (Weak & Semi Supervision)

除了数据和领域的不匹配问题, 实际应用中更大的瓶颈在于**标注成本极高**。弱监督和半监督正是为了降低对精确标注的依赖而发展出的两类重要学习范式。

弱监督学习 (Weak Supervision)

15.1.1 基本思想

弱监督的目标是在训练时使用程度更低、获取成本更低的标注 (例如只知道图像里有没有某类物体), 测试时却能够输出更精确的预测 (如边界框或分割掩码)。与半监督和全监督的关系见图:

- **全监督 (Supervised):** 所有训练样本都有完整标注 (如边界框)。
- **弱监督 (Weakly Supervised):** 只有弱标注 (如图像级类别标签)。
- **半监督 (Semi-supervised):** 少量样本有强标注, 大量未标注图像。
- **弱半监督 (Weakly Semi-supervised):** 部分样本有强标注, 其余只有弱标注。

15.1.2 多示例学习 (Multiple Instance Learning, MIL)

MIL 是实现弱监督学习的重要框架。训练样本被组织成**包 (Bag)**: 每个包 (例如一张图像) 包含多个**实例 (Instance)** (例如图像块)。

标准 MIL 假设:

- **负包**中所有实例都是负例。
- **正包**中至少有一个实例是正例 (称为**见证, Witness**)。

MIL 与传统监督学习的区别:

- 传统监督学习中, 每个实例都有独立标签。
- MIL 中, 只有包级别的标签已知, 实例标签未知且需要推断。

15.1.3 MIL 在目标检测中的典型策略

采用交替优化思想：

1. 估计物体外观模型 (Appearance Model)。
2. 利用该模型在正包中选择最可能是物体的区域。
3. 重复迭代直至收敛。

局限性：该过程导致非凸优化，优化质量严重依赖于初始化。为缓解这一问题，可先构建二分图，根据以下三条准则选择初始实例：

- **相关性 (Relevant)：**出现在许多正包中。
- **判别性 (Discriminative)：**与负包中的实例不相似。
- **互补性 (Complementary)：**捕获同一物体在特征空间中的多个模态（如不同姿态、颜色）。

注意：为包分类设计的 MIL 算法，其对实例的分类边界不一定最优（两个可能的最优边界可能一个能完美分类实例，另一个不能）。

半监督学习 (Semi-supervised Learning)

半监督学习的核心是同时利用少量有标签数据和大量未标签数据，通过挖掘未标签数据中蕴含的数据分布结构来提升模型性能。主要方法论包括：

15.2.1 自训练 (Self-Training)

- **伪标签 (Pseudo Labeling)：**先用有标签数据训练模型，然后对未标签数据预测硬标签（类别），再将高置信度的样本及其伪标签加入训练集，重复训练。
- **Noisy Student：**在伪标签的基础上还向学生模型注入噪声（如随机深度 Stochastic Depth），增强鲁棒性。

15.2.2 一致性正则化 (Consistency Regularization)

核心思想：对同一未标注图像施加不同扰动，模型的输出应保持不变。

1. **π -模型 (π -model)：**对同一图像生成两种随机增强，用其预测的均方误差 (MSE) 作为一致性损失，与有标签数据的交叉熵损失加权求和。
2. **Mean Teacher：**维护两个结构相同的模型——教师 (Teacher) 和学生 (Student)。教师权重是学生权重的**指数移动平均 (Exponential Moving Average, EMA)**：

$$\text{EMA}(t) = \text{data}(t) \times k + \text{EMA}(t-1) \times (1-k), \quad k = \frac{2}{N+1} \quad (47)$$

其中 N 为 EMA 考虑的数据长度。教师模型的预测作为学生模型在未标签数据上的目标。

3. **虚拟对抗训练 (Virtual Adversarial Training, VAT)：**生成对抗性扰动，使得原始图像与对抗图像之间模型输出的 KL 散度最大化。
4. **无监督数据增强 (Unsupervised Data Augmentation, UDA)：**使用 AutoAugment（自动从数据中学习最佳增强策略）对未标签图像进行增强，以增强前后预测的 KL 散度为一致性损失。有标签数据仅计算标准交叉熵。

15.2.3 混合方法: MixMatch

MixMatch 巧妙融合了自训练、一致性正则化和 MixUp 增强, 成为半监督学习的里程碑。

1. 对有标签图像做一次增强; 对每张未标签图像做 K 次增强, 取模型对 K 个增强样本的预测平均值, 再通过**温度缩放 (Temperature Scaling)** 得到更尖锐的伪标签。
2. 将增强后的有标签批和一组无标签批混合并随机打乱。
3. 对混合后的组应用 **MixUp**: 任意两个样本 (和对应标签) 按随机权重 $\lambda \in [0, 1]$ 线性组合:

$$\tilde{x} = \lambda x_i + (1 - \lambda) x_j, \quad \tilde{y} = \lambda y_i + (1 - \lambda) y_j \quad (48)$$

4. 分别计算有标签部分的交叉熵损失, 以及无标签部分与伪标签的均方误差损失, 加权求和作为总损失。

15.2.4 温度缩放 (Temperature Scaling)

神经网络往往校准不佳 (置信度与真实正确率不匹配)。温度缩放是一种后处理技术, 对 softmax 之前的 logits 向量 $\mathbf{z}$ 进行缩放:

$$p_i = \frac{\exp(z_i/T)}{\sum_j \exp(z_j/T)} \quad (49)$$

其中 T 为可学习的温度参数。 $T > 1$ 降低置信度, $T < 1$ 使分布更尖锐。该方法可使模型近似完美校准。

弱/半监督学习的本质讨论

- **共同原理**: 不依赖显式标签, 而是通过**结构约束 (Structural Constraints)** 从数据分布本身提取学习信号。
- **什么更根本?** 更好的**监督设计**比更好的模型更重要, 因为它直接定义了学习目标而非仅优化效率。
- **设计思路**: 给定丰富算力但稀缺标注的数据, 应优先设计精巧的弱监督或半监督框架, 利用先验知识 (如物体在空间中的共现、尺度关系) 来引导模型学习。

弱监督与半监督方法总结

- **弱监督**: 训练用弱标签, 测试需强输出; MIL 将样本组织为包, 正包至少含一个正实例。
- **半监督**:
 - 自训练: 伪标签迭代
 - 一致性正则化: π -model、Mean Teacher (EMA)、VAT、UDA
 - 混合方法: MixMatch = 温度缩放 + 伪标签 + MixUp
- **校准**: 温度缩放 $p_i = \exp(z_i/T) / \sum_j \exp(z_j/T)$
- **核心哲学**: 从数据分布引入的结构约束中无监督地产生学习信号

第十一周：自监督学习 (Self-Supervised Learning)

自监督学习是一种通过设计**伪监督任务 (Pseudo-supervised Task)** 从无标签数据中自动生成监督信号的学习范式。其核心思想是：利用数据本身的某种属性或结构构造“标签”，从而将无监督问题转化为有监督问题。

自监督学习的基本概念

定义： 自监督学习不依赖人工标注，而是通过数据的固有特性（如颜色、空间结构、时序关系）构造预测任务。例如：将图像随机旋转 $0^\circ, 90^\circ, 180^\circ, 270^\circ$ ，训练模型预测旋转角度。

典型伪监督任务示例：

- **重建 (Reconstruction)：** 图像着色 (Colorization)、超分辨率 (Super-resolution)、图像修复 (Inpainting)
- **常识推理 (Common Sense Reasoning)：** 拼图 (Jigsaw Puzzle)、上下文预测 (Context Prediction)、帧顺序验证 (Frame Order Verification)

自监督学习的价值： 在海量无标签数据上预训练 (Pre-train) 出强大的特征表示，然后通过少量标注数据进行微调 (Fine-tune) 或线性评估 (Linear Probing)，显著降低对人工标注的依赖。

自监督学习的两大范式

自监督学习范式

自监督学习方法主要分为两大类：**重建式 (Reconstructive / Auto-Encoding)** 和 **对比式 (Contrastive / Siamese)**。

重建式自监督学习：掩码自编码器 (Masked Auto-Encoders, MAE)

MAE (CVPR 2022) 是一种简单但高效的重建式自监督方法，核心设计包括：

1. **非对称编码器-解码器架构 (Asymmetric Encoder-Decoder)：**
 - 编码器 (Encoder) 仅处理**可见图像块 (Visible Patches)** (如保留 25% 的块)
 - 解码器 (Decoder) 处理所有块 (可见块 + 掩码块)，负责重建原始图像
2. **高掩码比例：** 通常掩码 75% 的图像块，使任务具有挑战性，促使模型学习语义信息而非简单插值。

训练流程：

1. 将图像划分为非重叠的块 (Patches)
2. 随机掩码掉大部分块 (如 75%)
3. 可见块输入编码器得到潜在表示
4. 在解码器中加入掩码块标记 (Mask Tokens)，通过解码器重建原始像素

下游任务使用：丢弃解码器，仅保留编码器用于特征提取。

掩码比例的影响：

- 掩码比例过低：任务太简单，模型学不到高级语义
- 掩码比例过高：可见信息太少，重建过于困难
- 推荐值：约 75%

对比式自监督学习

对比学习的核心目标是：使同一图像的不同增强版本（正样本对, Positive Pair）在表示空间中靠近，而不同图像的增强版本（负样本对, Negative Pair）相互远离。

16.4.1 带负样本的对比学习：SimCLR

SimCLR (ICML 2020) 的完整流程：

1. **数据增强 (Data Augmentation)**：对批次中每张图像随机应用两种增强（裁剪、翻转、颜色抖动、灰度化），得到 $2N$ 张增强图像。
2. **编码器 (Encoder)**：使用 ResNet-50 等网络提取特征 h (2048 维)。
3. **投影头 (Projection Head)**：通过 MLP（全连接 $\rightarrow$ ReLU $\rightarrow$ 全连接）将 h 映射到更低维空间 z 。
4. **相似度计算**：使用余弦相似度 (Cosine Similarity) 比较 z_i 和 z_j ：

$$s_{i,j} = \frac{z_i^\top z_j}{\tau \|z_i\| \|z_j\|} \quad (50)$$

其中 τ 为温度参数 (Temperature Parameter)，用于调节分布的尖锐程度。

5. **损失函数 (NT-Xent Loss)**：对于每个正样本对 (i, j) ，损失为：

$$\ell_{i,j} = -\log \frac{\exp(s_{i,j})}{\sum_{k=1}^{2N} \mathbf{1}_{k \neq i} \exp(s_{i,k})} \quad (51)$$

该形式为归一化温度缩放交叉熵损失，分母包含 1 个正样本和 $2N - 2$ 个负样本。

MoCo (CVPR 2020)：为解决 SimCLR 对大批量依赖的问题，引入：

- **动量编码器 (Momentum Encoder)**：参数缓慢更新，保证队列中表示的一致性
- **队列 (Queue)**：存储历史样本的表示，解耦批次大小与负样本数量

16.4.2 无负样本的对比学习：BYOL 与 SimSiam

BYOL (NeurIPS 2020): 完全不需要负样本，仍能避免模型坍塌 (Collapse)。其核心设计：

- 在线网络 (Online Network): 包含编码器、投影头和预测器 q_θ
- 目标网络 (Target Network): 动量编码器 + 投影头，参数为 $\xi = \text{EMA}(\theta)$
- 损失函数：预测 p 与目标 z' 之间的 L2 误差（或负余弦相似度）

SimSiam (CVPR 2021): 进一步简化 BYOL，完全移除动量编码器，仅依赖：

- 停梯度 (Stop-gradient, sg) 操作
- 负余弦相似度损失：

$$D(p, z) = -\frac{p}{\|p\|_2} \cdot \frac{z}{\|z\|_2}, \quad \text{且对 } z \text{ 执行 stop-gradient} \quad (52)$$

三种对比方法的对比总结

方法	使用负样本？	使用动量编码器？
SimCLR	是	否
MoCo	是	是
BYOL	否	是
SimSiam	否	否

Table 7: 三种对比式自监督学习方法的核心差异

案例研究：自监督场景去遮挡 (Self-Supervised Scene De-occlusion)

该任务 (CVPR 2020) 的目标是恢复物体的遮挡顺序并补全被遮挡的部分。其自监督策略包括：

- 利用实例分割数据集中的 modal mask（可见部分掩码）和类别标签
- 训练部分补全网络 (Partial Completion Network, PCNet-M)
- 通过设计“部分补全正则化”来区分哪些区域应该被补全（被遮挡）哪些不应修改（背景或前景物体自身边界）

自监督学习的本质讨论

- **核心机制**：从数据自身属性中自动生成监督信号，无需人工标注。
- **与弱/半监督的关系**：自监督学习可作为一种预训练策略，为下游任务（包括弱监督和半监督）提供强大的初始化特征。
- **未来趋势**：结合重建式与对比式的优点、多模态自监督（如视频 + 音频、图像 + 文本）是重要发展方向。

自监督学习核心要点总结

- **本质**：自动生成伪标签，从无标签数据中学习表示。
- **重建式 (MAE)**：掩码高比例输入，重建缺失部分 → 非对称编码器-解码器。
- **对比式 (SimCLR, MoCo, BYOL, SimSiam)**：
 - 正样本靠近，负样本远离（或无负样本）
 - 余弦相似度： $s_{i,j} = z_i^T z_j / (\tau \|z_i\| \|z_j\|)$
 - NT-Xent 损失：基于 softmax 的对比损失
 - BYOL/SimSiam 通过预测 + 停梯度避免坍塌
- **掩码比例建议**：约 75%
- **下游使用**：编码器特征 + 线性分类器或全模型微调

第十一周：轻量化计算机视觉 (Lightweight Computer Vision)

终端设备（如手机、嵌入式设备、微控制器）的计算资源、存储空间和功耗极其有限，这与日益庞大的深度学习模型形成了尖锐矛盾。轻量化计算机视觉旨在通过模型压缩、高效算子设计和轻量化架构搜索等技术，在保持较高精度的前提下显著降低模型的计算量和参数量。

轻量化技术概览 (Lightweight Techniques)

PPT 中归纳了六类主要的模型轻量化/加速技术：

- **模型小型化 (Down-sizing Models)**：直接设计或搜索更小的稠密模型，如通过知识蒸馏 (Distillation) 或神经架构搜索 (Neural Architecture Search, NAS)。
- **算子分解 (Operator Factorization)**：将大矩阵分解为两个或多个小矩阵的乘积，减少参数量。例如 $W[n \times m] = A[n \times r] \cdot B[r \times m]$ ，其中 $r \ll \min(n, m)$ 。
- **数值量化 (Value Quantization)**：使用低精度数值（如 INT8、INT4）表示权重和激活值，替代原始的 FP32，可大幅减少存储和内存带宽。
- **数值压缩 (Value Compression)**：利用熵编码（如 Huffman 编码）或相关性编码（如 gzip）对模型参数进行无损或有损压缩。
- **参数共享 (Parameter Sharing)**：在多个神经元之间复用参数，如 ShapeShifter 网络或卷积神经网络 (CNN) 本身就天然具有权重共享特性。
- **稀疏化 (Sparsification)**：通过剪枝 (Pruning) 等技术使网络权重或激活值变得稀疏，从而压缩模型并加速计算。

稀疏化的原理与动机

研究表明，深度神经网络普遍存在严重的过参数化 (Over-parameterization) 现象。例如，在某些网络中，仅需 5% 的参数即可预测剩余的 95% 参数。尽管过参数化有利于梯度下降的收敛和优化，但它带来了巨大的存储和计算开销。

稀疏化的核心理念：并非所有特征在所有时候都是相关的。通过稀疏表示，可以实现：

- 减少过拟合
- 提升可解释性
- 符合奥卡姆剃刀 (Occam's Razor) 原则——“如无必要，勿增实体”

从全连接到卷积：稀疏性归纳偏置的典范：卷积神经网络 (CNN) 本身就是稀疏化思想的成功应用：

- **全连接 (Fully Connected)：**通用近似能力强，但参数极多，难训练。
- **局部连接 (Locally Connected)：**引入局部性归纳偏置，降低复杂度。
- **卷积 (Convolutional)：**进一步引入平移等变性 (Translational Equivariance)，极大减少参数，成为图像识别/检测的标配。

小模型训练的特殊挑战：网络增强 (Network Augmentation)

传统正则化技术（如数据增强、Dropout）在大模型上效果显著，但在小模型上反而可能损害性能。这是因为小模型容量不足，主要问题是欠拟合 (Under-fitting) 而非过拟合。

网络增强 (Network Augmentation, ICLR 2022) 针对小模型提出：

- 训练时将一个小网络（用于最终推理）增强为多个共享权重的大网络（如拓宽宽度、增加分支）。
- 推理时仅使用原始小网络，零额外开销。
- 损失函数包含基础监督和辅助监督：

$$\mathcal{L}_{\text{aug}} = \underbrace{\mathcal{L}(W_t)}_{\text{base supervision}} + \sum_i \alpha_i \underbrace{\mathcal{L}([W_t, W_i])}_{\text{auxiliary supervision}} \quad (53)$$

其中 W_t 是基础小网络的权重， W_i 是增强分支的额外权重。

高效算子设计：PConv 与 FasterNet

计算复杂度通常用浮点运算次数 (FLOPs) 衡量。在硬件上，一次乘加运算 (Multiply-Accumulate, MAC) 通常计为 1 FLOP：

$$a \leftarrow a + (b \times c) \quad (54)$$

标准卷积 vs 深度卷积 vs 部分卷积：

- **标准卷积 (Regular Conv)：**输入 c 通道，输出 c 通道，卷积核 $k \times k$ ， $\text{FLOPs} \approx h \times w \times k^2 \times c^2$ 。
- **深度卷积 (Depthwise Conv, DWConv)：**每个通道单独卷积， $\text{FLOPs} \approx h \times w \times k^2 \times c$ ，参数量显著降低，但内存访问成本可能增加。

部分卷积 (Partial Conv, PConv) 进一步优化：

- 仅在输入通道的一部分（前 c_p 个通道）上应用标准卷积，其余通道保持不动。
- 随后接一个逐点卷积 (Pointwise Conv, PwConv) 融合所有通道信息。
- FLOPs 约为 $h \times w \times k^2 \times c_p^2$ ，内存访问约为 $h \times w \times 2c_p$ 。
- 基于 PConv 构建的 FasterNet 在精度/效率权衡上表现优异。

轻量化 ViT 架构: EdgeViT

EdgeViT (ECCV 2022) 首次使视觉 Transformer (ViT) 在移动设备上达到与顶级轻量 CNN (如 MobileNetV2、EfficientNet) 相当的精度/效率权衡。

核心设计: 局部-全局-局部 (Local-Global-Local, LGL) 块

1. **局部聚合 (Local Aggregation)**: 通过深度卷积和逐点卷积在局部窗口内聚合信息。
2. **稀疏全局注意力 (Sparse Self-Attention)**: 仅对均匀采样的“代表令牌”子集 (采样率为 r) 计算自注意力, 大幅降低计算量。
3. **局部传播 (Local Propagation)**: 通过转置卷积 (Transposed Convolution) 将代表令牌上的全局上下文信息传播回其邻居令牌。

通过这种瓶颈式设计, EdgeViT 在保持全局感受野的同时, 显著降低了 Transformer 的计算复杂度。

轻量化检测器: Lite DETR

原始 DETR (Detection Transformer) 仅使用高层的低分辨率特征, 缺乏对小物体至关重要的局部细节。引入多尺度特征 (高分辨率 + 低分辨率) 可提升检测性能, 但会大幅增加 token 数量。

Lite DETR 的解决方案:

- **交错更新 (Interleaved Update)**: 高频更新高层特征 (视为主要特征, token 数量少), 低频更新低层特征 (token 数量多), 从而降低总计算量。
- **键感知可变形注意力 (Key-Aware Deformable Attention, KDA)**: 为每个查询 (Query) 在键 (Key) 和值 (Value) 上进行联合采样, 进一步提升效率。

实验表明, Lite DETR 可将检测头的 GFLOPs 降低 60%, 同时保持 99% 的原始性能。

轻量化技术的本质讨论

- **核心矛盾**: 模型容量 (表达能力) 与资源消耗 (计算/存储/功耗) 之间的权衡。
- **设计哲学**:
 - **结构化稀疏**: 如卷积的局部连接、分组卷积、注意力中的稀疏采样, 通过设计固有的稀疏模式减少冗余计算。
 - **低秩分解**: 如算子分解, 利用参数的冗余性进行压缩。
 - **低精度量化**: 用更少的比特表示数值, 直接降低存储和带宽需求。
 - **架构搜索**: 在给定资源约束下自动寻找最优的模型结构。
- **小模型特有规律**: 小模型的问题通常是欠拟合而非过拟合, 需要网络增强等专门技术。

轻量化计算机视觉核心要点总结

- **动机**：终端设备资源有限（存储、算力、功耗），无法直接部署大模型。
- **主要技术路线**：
 - 模型小型化（蒸馏、NAS）
 - 算子分解（低秩分解 $W = AB$ ）
 - 数值量化（FP32 $\rightarrow$ INT8/INT4）
 - 稀疏化（剪枝、稀疏注意力）
 - 高效算子（深度卷积 DWConv、部分卷积 PConv）
- **关键指标**：FLOPs（浮点运算次数）、MAC（乘加运算）、内存访问量
- **典型轻量架构**：
 - **FasterNet**：基于 PConv 的高效骨干网络
 - **EdgeViT**：LGL 块实现轻量 ViT（局部聚合 $\rightarrow$ 稀疏全局注意力 $\rightarrow$ 局部传播）
 - **Lite DETR**：交错更新 + KDA 实现高效多尺度检测
- **小模型训练**：网络增强 (Network Augmentation) 通过权重共享的多分支辅助监督缓解欠拟合

第十二周：生成式计算机视觉 (Generative Computer Vision)

生成式计算机视觉的目标不仅是理解图像，更是学习数据背后的分布 $p_{\text{data}}(x)$ ，并从中生成全新的、真实的样本。本章介绍从自编码器到扩散模型的演进路径。

无监督生成模型 (Unconditional Generative Models)

18.1.1 自编码器 (Autoencoders, AE)

自编码器由**编码器 (Encoder)**和**解码器 (Decoder)**组成，将高维输入压缩到低维隐空间再重建。

- **目标**：最小化重建误差 (Reconstruction Error)

$$(e^*, d^*) = \arg \min_{(e, d) \in E \times D} \epsilon(x, d(e(x))) \quad (55)$$

- **局限性**：隐空间不连续、无规则，无法直接用于生成新样本。

18.1.2 变分自编码器 (Variational Autoencoders, VAE)

VAE 对编码分布引入正则化，使其接近标准正态分布，从而获得规则、连续的隐空间。

- **损失函数：**重建损失 + KL 散度

$$\mathcal{L} = \underbrace{\|x - \hat{x}\|^2}_{\text{Reconstruction}} + D_{KL}(q(z|x) \| p(z)) \quad (56)$$

其中 $p(z) \sim \mathcal{N}(0, I)$, D_{KL} 为 Kullback-Leibler 散度。

- **重参数化技巧 (Reparameterization Trick)：**使反向传播可行

$$z = \mu_x + \sigma_x \odot \epsilon, \quad \epsilon \sim \mathcal{N}(0, I) \quad (57)$$

- **隐空间性质：**
 - **连续性 (Continuity)：**相近的隐向量解码出相近的内容。
 - **完备性 (Completeness)：**从隐空间任意点采样都能解码出有意义的内容。

18.1.3 生成对抗网络 (Generative Adversarial Networks, GAN)

GAN 通过生成器 (Generator) 与判别器 (Discriminator) 的对抗博弈进行训练。

- **理想平衡：**生成样本与真实样本不可区分，判别器输出概率为 0.5。
- **训练过程：**
 - 判别器：最大化 $\log D(x) + \log(1 - D(G(z)))$
 - 生成器：最小化 $\log(1 - D(G(z)))$
- **特点：**间接比较（对抗），而非直接比较重建误差。

18.1.4 基于分数的生成模型 (Score-Based Generative Models)

分数函数 (Score Function) 为避免计算归一化常数，直接建模对数概率密度的梯度：

$$s_\theta(x) = \nabla_x \log p_\theta(x) = -\nabla_x f_\theta(x) \quad (58)$$

分数匹配 (Score Matching) 通过最小化 Fisher 散度来训练分数模型：

$$\frac{1}{2} \mathbb{E}_{p_{\text{data}}(x)} [\|\nabla_x \log p_{\text{data}}(x) - s_\theta(x)\|_2^2] \quad (59)$$

实际使用可计算的代理目标：

$$\frac{1}{N} \sum_{i=1}^N \left[\frac{1}{2} \|s_\theta(x_i)\|_2^2 + \text{trace}(\nabla_x s_\theta(x_i)) \right] \quad (60)$$

朗之万动力学采样 (Langevin Dynamics Sampling)

$$x_{i+1} \leftarrow x_i + \epsilon \nabla_x \log p(x) + \sqrt{2\epsilon} z_i, \quad z_i \sim \mathcal{N}(0, I) \quad (61)$$

多尺度噪声退火 (Annealed Langevin Dynamics)

- **问题：**低密度区域分数估计不准确。
- **解决：**使用多个噪声尺度 $\sigma_1 < \sigma_2 < \dots < \sigma_L$ 扰动数据。
- **训练噪声条件分数网络 (Noise Conditional Score Network, NCSN)** $s_\theta(x, i)$ 。
- 从最大噪声尺度开始，逐步退火采样。

扩散模型 (Diffusion Models) 与 SDE 视角

18.2.1 连续时间随机微分方程 (Stochastic Differential Equations, SDE)

将有限个噪声尺度推广到无穷，形成连续的扩散过程。

- **前向 SDE (数据 $\rightarrow$ 噪声)：**

$$d\mathbf{x} = \mathbf{f}(\mathbf{x}, t)dt + g(t)d\mathbf{w} \quad (62)$$

- **反向 SDE (噪声 $\rightarrow$ 数据)：**

$$d\mathbf{x} = [\mathbf{f}(\mathbf{x}, t) - g^2(t)\nabla_x \log p_t(\mathbf{x})]dt + g(t)d\mathbf{w} \quad (63)$$

- **关键：**需要估计每个时刻的分数函数 $\nabla_x \log p_t(\mathbf{x})$ 。

18.2.2 去噪扩散概率模型 (Denoising Diffusion Probabilistic Models, DDPM)

DDPM 是扩散模型的离散化实现，使用 U-Net 结构预测噪声。

- **训练目标：**

$$L = \|\epsilon - \epsilon_\theta(x_t, t)\|^2 \quad (64)$$

- **采样公式：**

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z, \quad z \sim \mathcal{N}(0, I) \quad (65)$$

条件生成与引导 (Conditional Generation & Guidance)

18.3.1 分类器引导 (Classifier Guidance)

利用额外训练的分类器引导生成特定类别：

$$\nabla_x \log p_\gamma(x|y) = \nabla_x \log p(x) + \gamma \nabla_x \log p(y|x) \quad (66)$$

18.3.2 无分类器引导 (Classifier-Free Guidance)

无需单独分类器，直接利用条件生成模型：

$$\nabla_x \log p_\gamma(x|y) = (1 - \gamma) \nabla_x \log p(x) + \gamma \nabla_x \log p(x|y) \quad (67)$$

- **实现技巧：**训练时以一定概率（如 10-20%）随机丢弃条件信息（Conditioning Dropout），使同一模型同时学习条件生成和无条件生成。
- **优势：**效果优于分类器引导，避免分类器带来的偏差。

生成模型的应用与评估

- **图像修复 (Inpainting)**: 直接指定前向模型约束。
- **图像着色 (Colorization)**: 利用扩散模型逐步恢复颜色。
- **语言引导生成 (Language-Guided Generation)**: 如 GLIDE 模型, 文本作为条件。
- **似然评估 (Likelihood Evaluation)**: 通过求解 ODE 计算精确对数似然, 用于:
 - 无损压缩
 - 无监督异常检测
 - 生成式分类
 - 密度估计

生成模型演进总结

- **AE**: 编码器-解码器, 最小化重建误差
- **VAE**: 隐空间正则化 (KL 散度), 重参数化技巧
- **GAN**: 生成器与判别器对抗, 达到纳什均衡
- **分数模型**: 学习 $\nabla_x \log p(x)$, 使用 Langevin 动力学采样
- **扩散模型 (DDPM)**: 学习去噪过程, 训练目标 $L = \|\epsilon - \epsilon_\theta(x_t, t)\|^2$
- **SDE 视角**: 前向扩散 $\rightarrow$ 反向生成, 统一框架
- **条件生成**: 无分类器引导 $= (1 - \gamma)\nabla \log p(x) + \gamma\nabla \log p(x|y)$

第十三周: 视觉语言模型 (Vision-Language Models)

视觉语言模型旨在对齐视觉与语言两种模态, 通过海量图像-文本对学习通用的视觉表征, 并支持零样本推理与提示工程。

视觉语言模型基础

19.1.1 多模态与对比预训练

传统视觉系统受限于固定类别集, 而视觉语言模型直接从原始文本中学习, 利用更广泛的监督信号。

- **核心架构**: 双编码器结构
 - **图像编码器**: ResNet 或 Vision Transformer (ViT)
 - **文本编码器**: Transformer
 - 两者将输入映射到同一嵌入空间
- **对比学习目标**: 最大化匹配的图像-文本对之间的余弦相似度, 最小化不匹配对之间的相似度。

- **InfoNCE 损失函数：**

$$L_I = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\sin(z_i^I, z_i^T)/\tau)}{\sum_{j=1}^N \exp(\sin(z_i^I, z_j^T)/\tau)} \quad (68)$$

其中 τ 为可学习的温度参数， $\sin(\cdot, \cdot)$ 表示余弦相似度。

- **训练数据：** CLIP 使用 4 亿图像-文本对；LAION-5B 达 50 亿规模。

19.1.2 零样本推理

- **核心思想：** 将类别名称转化为句子（如 “a photo of a dog”），通过文本编码器合成分类权重。
- **预测概率：**

$$p(y = i|x) = \frac{\exp\left(\frac{\cos(T_i, I)}{\tau}\right)}{\sum_{j=1}^N \exp\left(\frac{\cos(T_j, I)}{\tau}\right)} \quad (69)$$

- **CLIP 的优势：**

1. 仅需图像-文本对，无需人工类别标签
2. 大规模数据学习通用视觉概念
3. 文本描述提供多方面的图像特征

19.1.3 描述性分类 (Descriptive Classification)

传统零样本分类仅使用类别名称，忽略语言的丰富上下文信息。描述性分类通过大语言模型（如 GPT-3）生成类别相关的视觉描述符。

- **分类得分：**

$$s(c, x) = \frac{1}{|D(c)|} \sum_{d \in D(c)} \phi(d, x) \quad (70)$$

其中 $D(c)$ 为类别 c 的描述符集合， $\phi(d, x)$ 为描述符 d 与图像 x 的匹配概率。

- **可解释性：** 模型可输出基于具体视觉特征（如 “条纹”、“爪子”）的分类依据。

提示工程 (Prompt Engineering)

19.2.1 Context Optimization (CoOp)

CoOp 通过可学习的连续向量替代人工设计的提示模板，避免手动调优。

- **统一上下文：**

$$t = [\mathbb{V}]_1 [\mathbb{V}]_2 \dots [\mathbb{V}]_M [\text{CLASS}] \quad (71)$$

其中 $[\mathbb{V}]_m$ 为与词嵌入同维度的可学习向量， M 为上下文 token 数量。

- **类别特定上下文：** 每类独立学习上下文向量，适用于细粒度分类。
- **局限：** 静态上下文难以泛化到未见类别。

19.2.2 Conditional Context Optimization (CoCoOp)

CoCoOp 引入轻量级神经网络，为每个图像生成输入条件化的提示 token。

- **核心思想：**提示依赖于输入实例，而非固定不变。
- **优势：**显著提升对未见类别的泛化能力。

19.2.3 Task Residual Tuning (TaskRes)

TaskRes 直接在基于文本的分类器上操作，显式解耦预训练模型的旧知识和目标任务的新知识。

- **两种调优范式的缺陷：**
 1. 提示调优缺乏对先验知识保留的保证
 2. 适配器式调优的新知识探索灵活性有限
- **解决方案：**任务残差学习，平衡旧知识继承与新知识探索。

19.2.4 视觉指令调优 (Visual Instruction Tuning)

- **目标：**增强模型对指令的理解能力，使通用大模型适配领域特定任务。
- **应用示例：**视觉情感识别任务中，使用图像级指令调优，仅需不到 50% 的训练数据即可超越 SOTA 识别模型。

视觉语言模型的应用

19.3.1 场景文本检测：TCM (Turning CLIP Model)

- **挑战：**监督文本检测需要精细的标注（字符级、词级、行级边界框）。
- **TCM 方案：**无需预训练过程，直接使用 CLIP 模型进行文本检测。
- **关键技术：**
 - 通过视觉提示学习设计跨模态交互机制，恢复 CLIP 图像编码器的局部特征。
 - 使用 Transformer 解码器的交叉注意力机制建模图像与文本嵌入的交互。
 - 实例-语言匹配机制生成二值文本分割图。

- **总损失：**

$$\mathcal{L}_{total} = \mathcal{L}_{det} + \lambda \mathcal{L}_{aux} \quad (72)$$

19.3.2 计数能力增强：Teaching CLIP to Count

- **目标：**提升预训练视觉语言模型对数量概念的定量理解。
- **两阶段框架：**
 1. 自动创建计数训练集：包含干净、多样化的图像及描述物体数量的标题。
 2. 使用基于计数的对比损失微调模型。

- 损失函数：

$$L = L_{CLIP} + \lambda L_{count} \quad (73)$$

其中 L_{count} 仅在计数训练集上计算， $\lambda = 1$ 为默认值。

- 数据示例：“two zebras in Cape Town” , “set of ten high back lucite dining chairs”。

视觉语言模型的压缩：TinyCLIP

TinyCLIP 通过亲和力模仿 (Affinity Mimicking) 对大规模语言-图像预训练模型进行蒸馏压缩。

- 目标：让学生模型模仿大模型在视觉-语言对齐学习中的行为。
- 开源实现：OpenCLIP (https://github.com/mlfoundations/open_clip)

迈向人类级智能

- 人类认知特性：组合性 (Compositionality)——人类通过将场景分解为不同概念（如计数）来理解场景。
- 当前局限：现有视觉语言模型在组合性任务上远未达到人类水平。
- 改进方向：通过特定任务的数据增强和损失函数设计，针对性地增强模型的特定认知能力。

视觉语言模型核心要点总结

- **CLIP 核心**：双编码器 + 对比学习 (InfoNCE)，4 亿图文对预训练
- **零样本推理**：文本编码器合成分类权重，无需微调即可泛化到新类别
- **描述性分类**：利用 LLM 生成视觉描述符，提升可解释性与分类性能
- **提示工程演进**：手工提示 → CoOp (学习连续向量) → CoCoOp (输入条件化) → TaskRes (知识解耦)
- **指令调优**：增强模型对指令的理解，适配领域特定任务
- **应用拓展**：场景文本检测、计数能力增强、模型压缩蒸馏
- **未来挑战**：组合性推理、人类级概念理解